第2回　機械学習基礎

講義講師：河野慎
演習講師：鄭晟徹

許諾なく撮影や第三者
への開示を禁止します

©Yutaka Matsuo. All rights reserved.

全体の位置づけ

#	タイトル
1	人工知能の概要とディープラーニングの意義
2	機械学習基礎
3	ニューラルネットワーク基礎
4	ニューラルネットワークの最適化・正則化
5	畳み込みニューラルネットワーク
6	深層学習と画像認識
7	回帰結合型ニューラルネットワークと系列データ処理
8	Transformer基礎
9	大規模言語モデルと自然言語処理
10	表現学習と自己教師あり学習
11	深層強化学習
12	深層生成モデル

©Yutaka Matsuo. All rights reserved.

今回の目的と目標

- **目的**
  - 深層学習を学ぶ事前知識として，機械学習の概要を把握する

- **目標**
  - 機械学習とは何かを、枠組み（モデル，学習，推論）と共に説明できる
  - 機械学習にどういったアプリケーションがあるのかを説明できる
  - 分類問題と回帰問題の違いを説明できる
  - モデルの評価基準や観点を説明できる（汎化性能，過学習，性能指標…）
  - 数式を含めてロジスティック回帰を説明できる

©Yutaka Matsuo. All rights reserved.

目次

- 機械学習の概要
  - 導入，応用事例の紹介
- 機械学習モデル
  - モデルとは何か
  - 学習と推論
  - 教師あり学習
    - 分類問題，回帰問題
- 機械学習モデルの評価・選択
- ロジスティック回帰

©Yutaka Matsuo. All rights reserved.

目次

- **機械学習の概要**
  - 導入，応用事例の紹介

- 機械学習モデル
  - モデルとは何か
  - 学習と推論
  - 教師あり学習
    - 分類問題，回帰問題

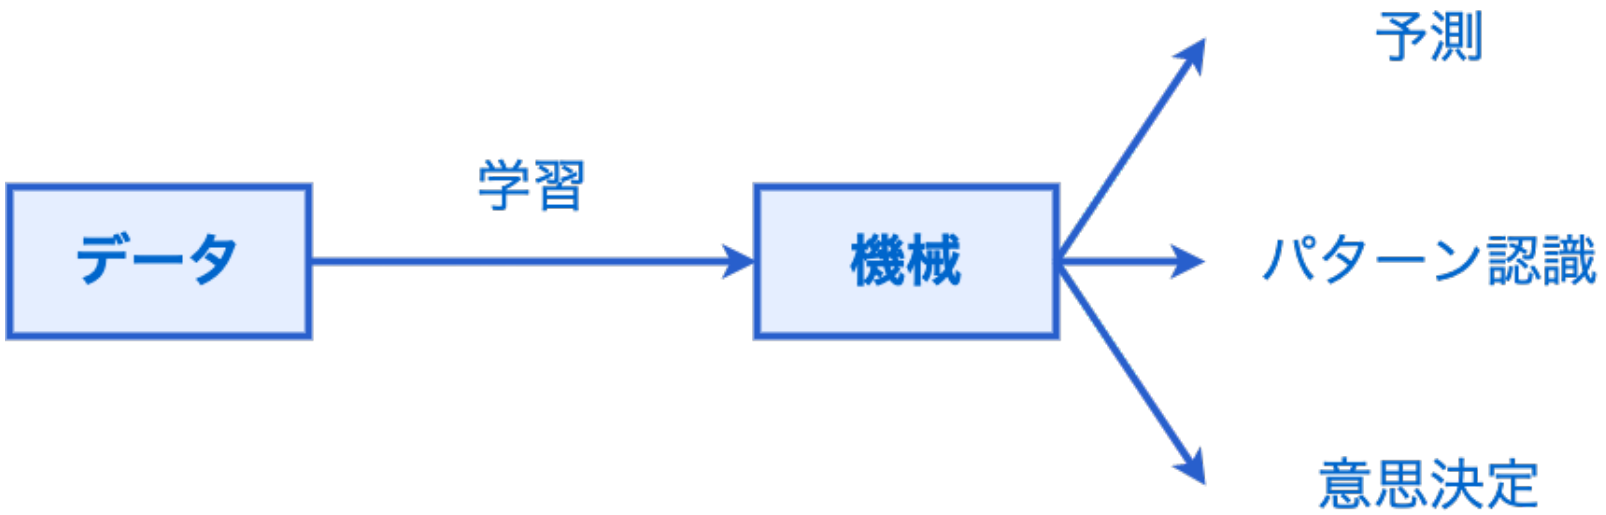
- 機械学習モデルの評価・選択

- ロジスティック回帰

©Yutaka Matsuo. All rights reserved.

機械学習の概要

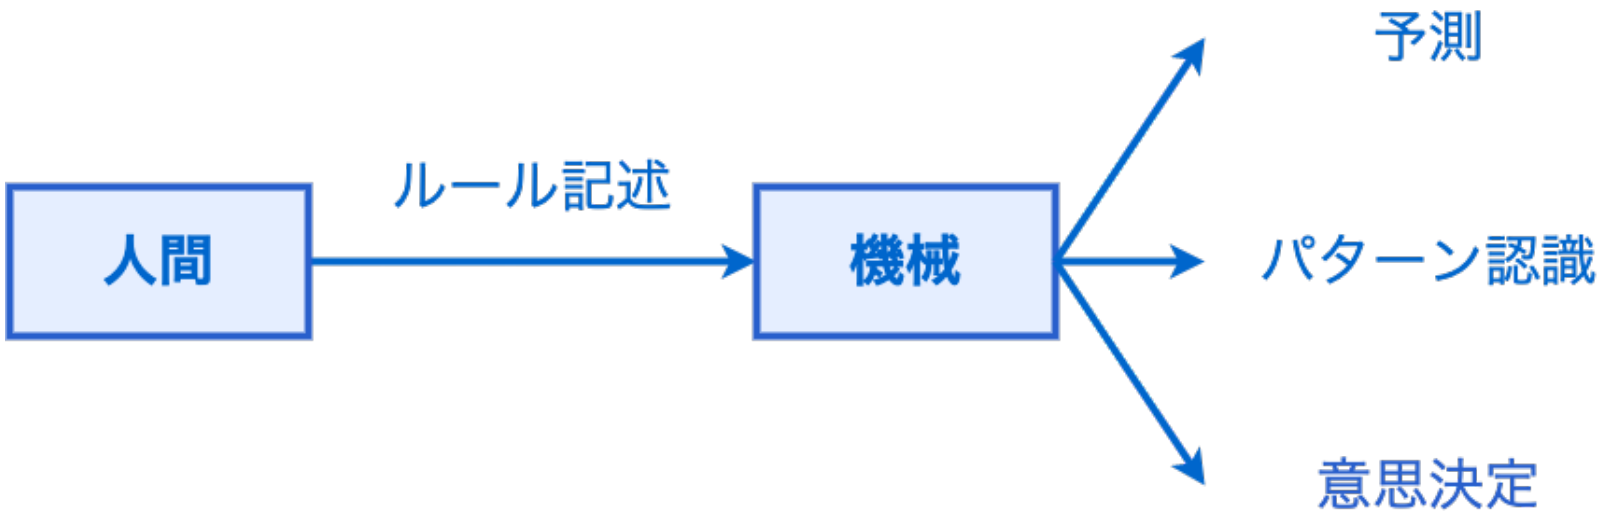
- **機械学習（Machine Learning ; ML）**
  - データ集合からパターンや表現，判断ルールなどを自動で獲得する手法



©Yutaka Matsuo. All rights reserved.

機械学習の概要

- ルールベースAI
  - 人間がパターンや表現，判断ルールなどを記述する



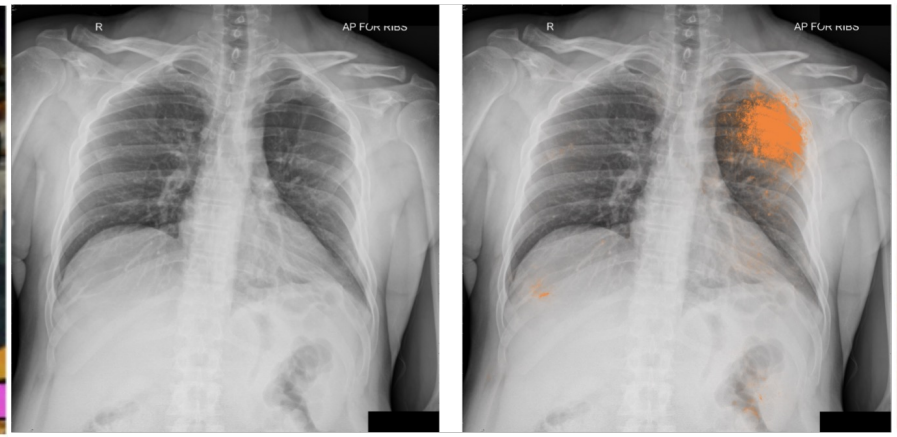
©Yutaka Matsuo. All rights reserved.

機械学習の概要

- 機械学習のアプリケーション（画像処理）
  - 一般物体認識，顔認識，表情認識，セグメンテーション，自動運転
    医療画像解析，画像説明文生成



https://cocodataset.org/#captions-2015
https://cocodataset.org/#detection-2015



https://ai.googleblog.com/2019/12/developing-deep-learning-models-for.html



The man at bat readies to swing at the pitch while the umpire looks on.

©Yutaka Matsuo. All rights reserved.

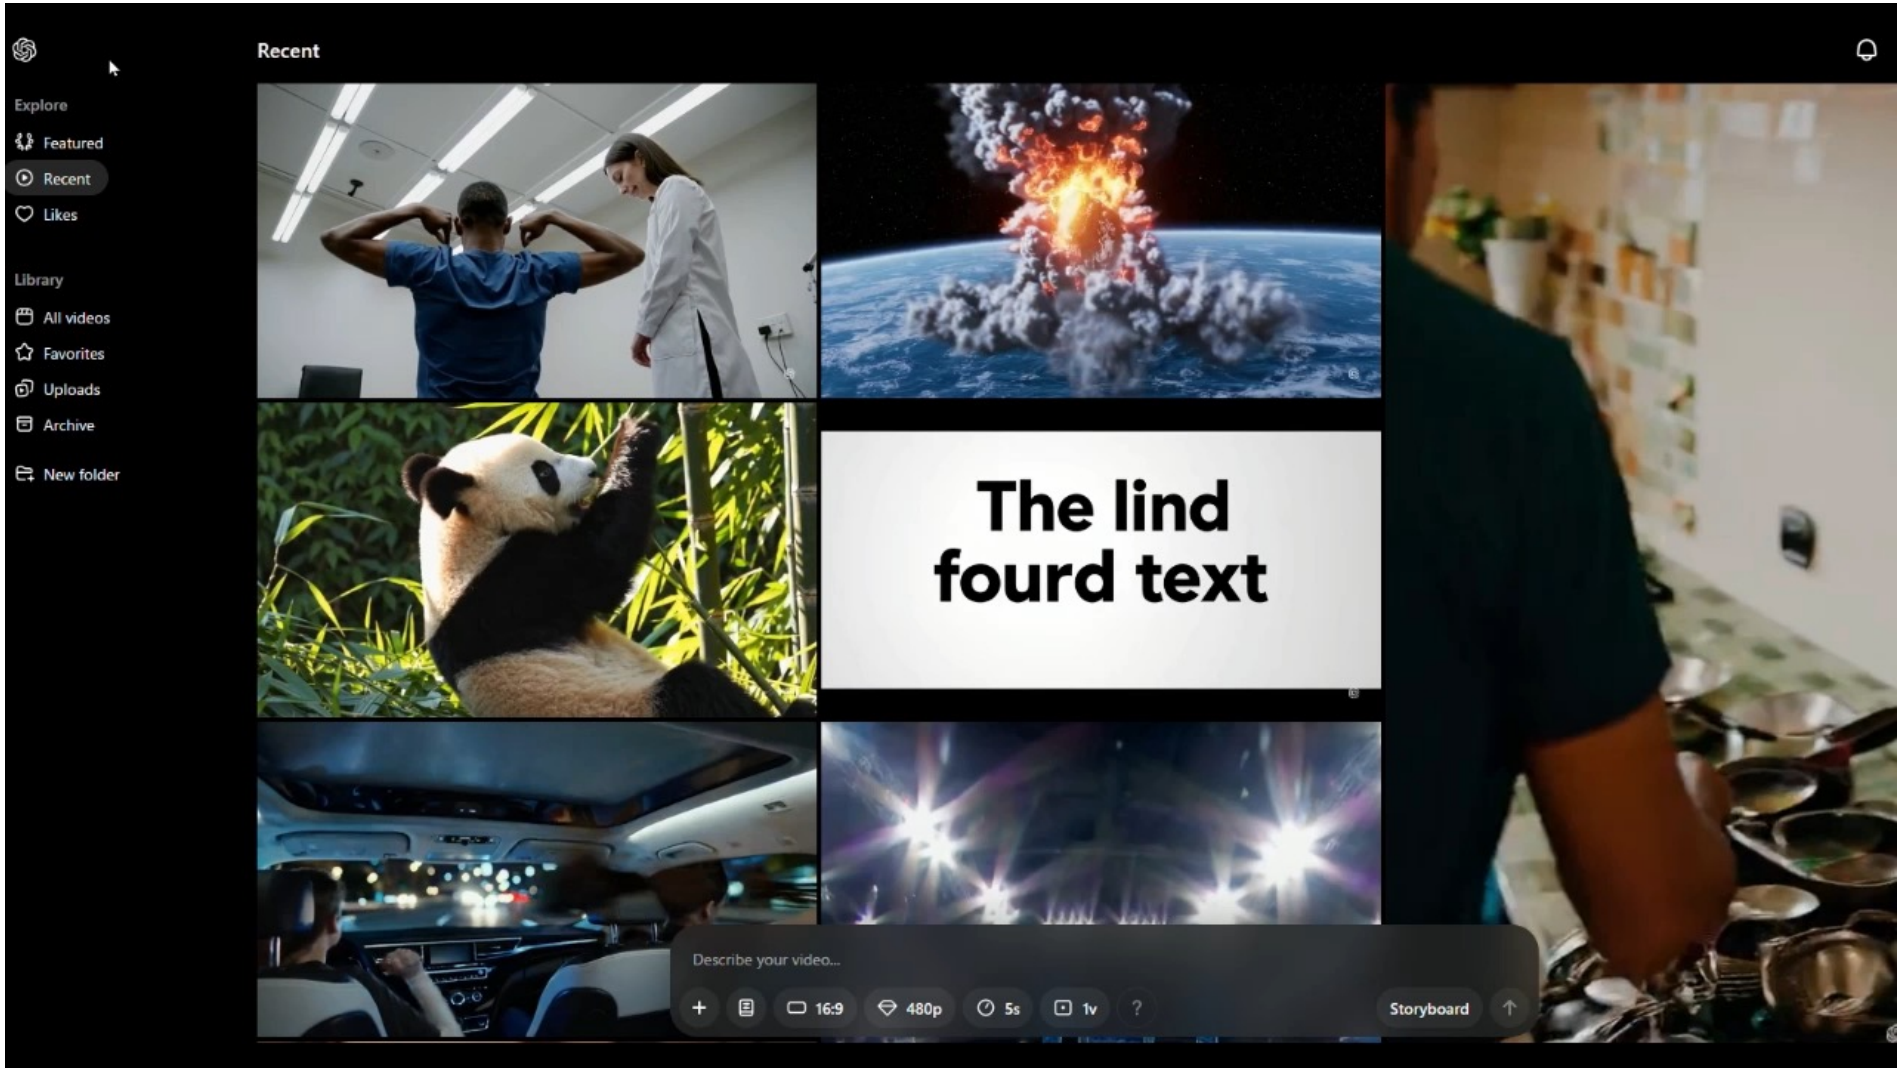
動画予測モデルデモ



NVIDIA Cosmos: A World Foundation Model Platform for Physical AI

©Yutaka Matsuo. All rights reserved.

動画生成デモ(苦手な方はご注意ください)



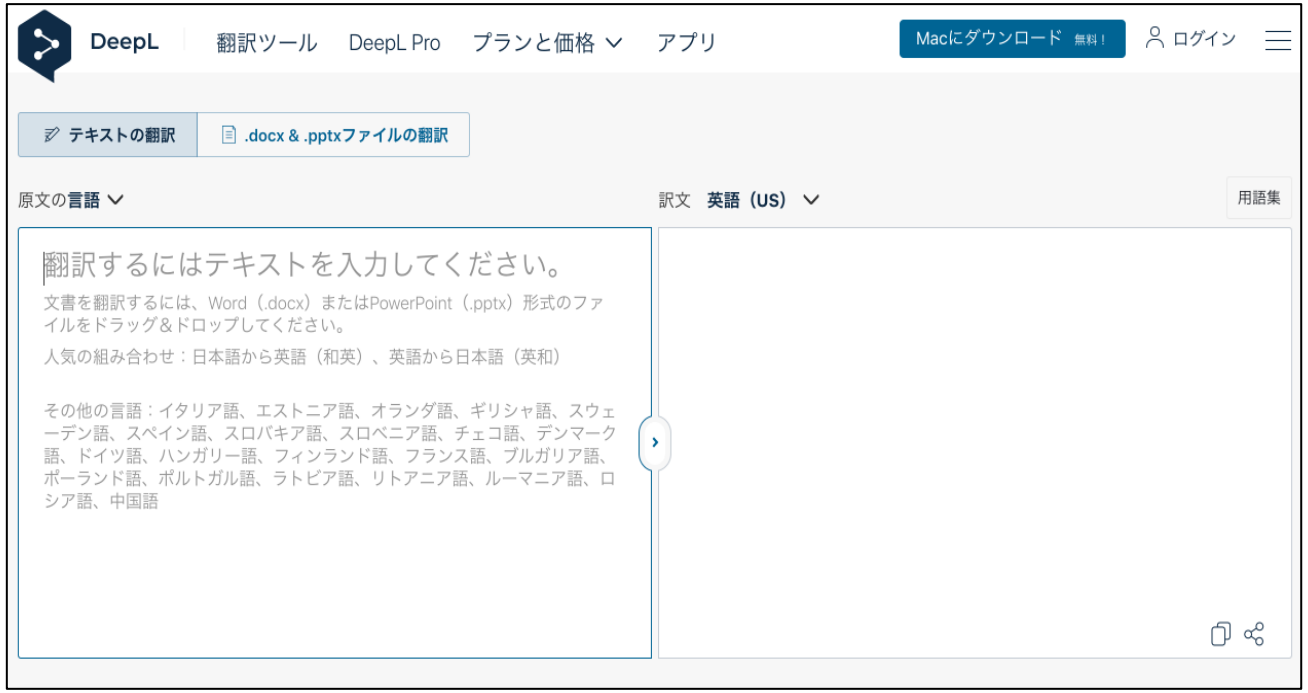
https://sora.com

©Yutaka Matsuo. All rights reserved.

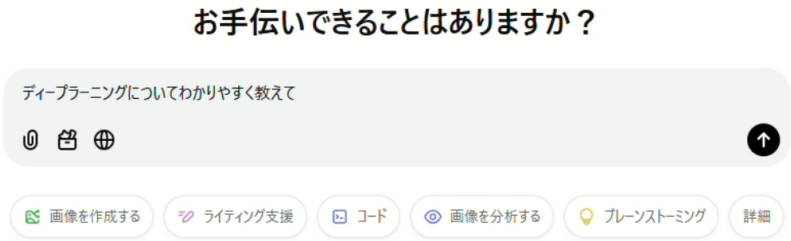
自然言語処理デモ

- 機械学習のアプリケーション（自然言語処理）

  機械翻訳，質問応答，対話システム
  要約文生成，画像説明文生成，コード生成



https://www.deepl.com/ja/translator



ChatGPT 4o 2025/01/21作成

©Yutaka Matsuo. All rights reserved.

プログラミングコード生成



https://www.youtube.com/watch?v=DeO7xLXORpY

©Yutaka Matsuo. All rights reserved.

機械学習の定義

- **経験（Experience）**から**学習（Learning）**することで**性能（Performance）**を改善するプログラム

- 例：
  - 経験：大量の学習データとして与えられる
  - 性能：機械学習モデルの予測と正解の誤差によって測る
  - 学習：学習データを用いてより良いモデルに更新する

©Yutaka Matsuo. All rights reserved.

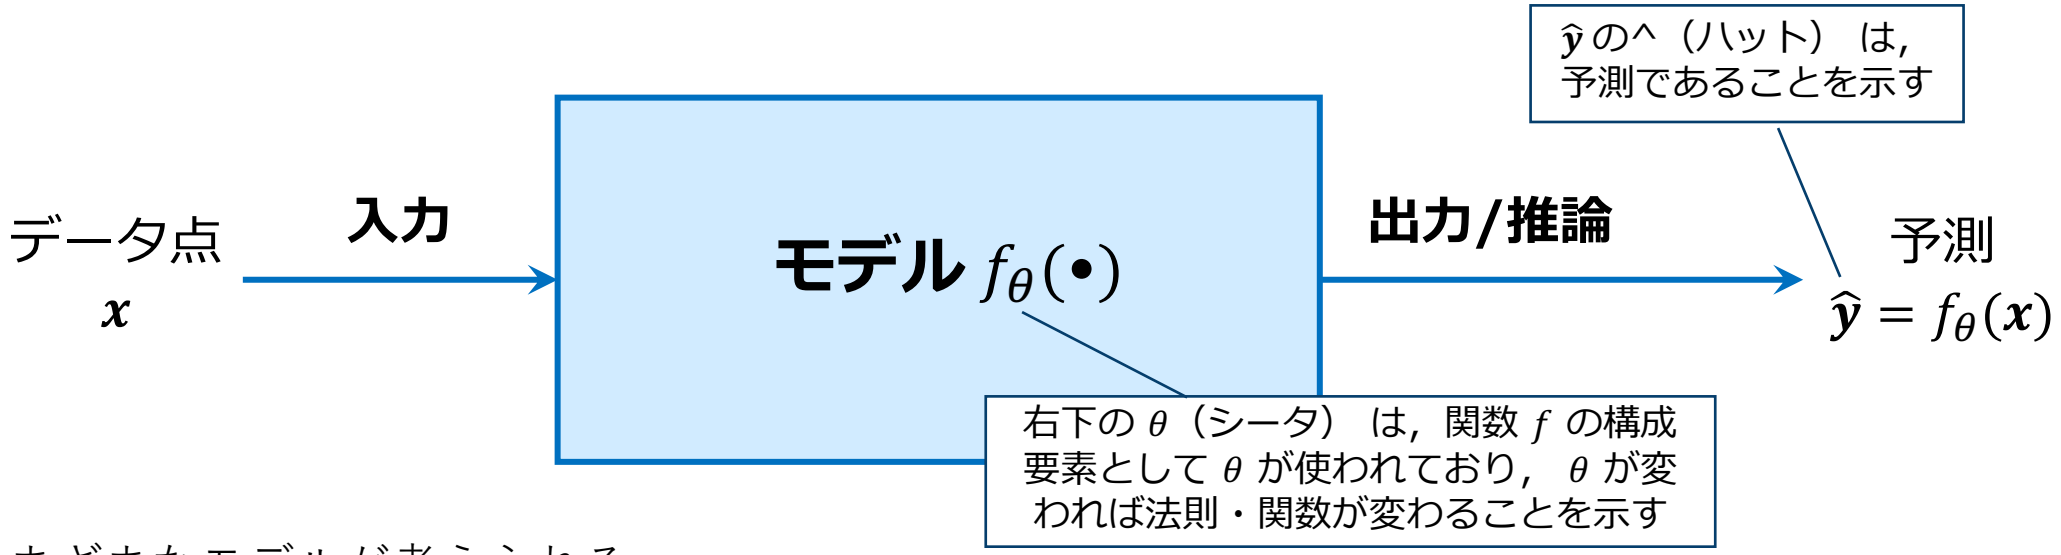
目次

- 機械学習の概要
  - 導入，応用事例の紹介
- **機械学習モデル**
  - モデルとは何か
  - 学習と推論
  - 教師あり学習
    - 分類問題，回帰問題
- 機械学習モデルの評価・選択
- ロジスティック回帰

©Yutaka Matsuo. All rights reserved.

モデルとは何か？

- モデルとは、入力を元に出力を予測するための法則・関数の記述である

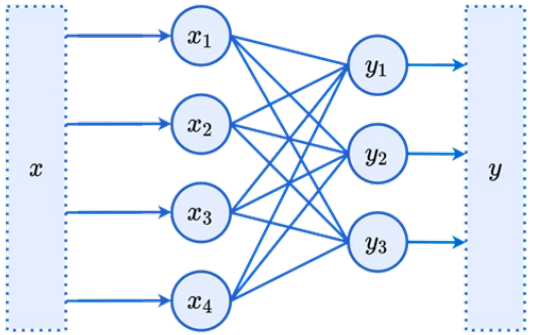


さまざまなモデルが考えられる

単回帰分析の例：$f_\theta(\boldsymbol{x}) = \alpha + \beta x$ （この場合 $\theta = (\alpha, \beta)$）

単層パーセプトロンの例（この場合 $\theta = (\boldsymbol{W}, \boldsymbol{b})$）

$$f_\theta(\boldsymbol{x}) = \boldsymbol{W}^T\boldsymbol{x} + \boldsymbol{b}$$

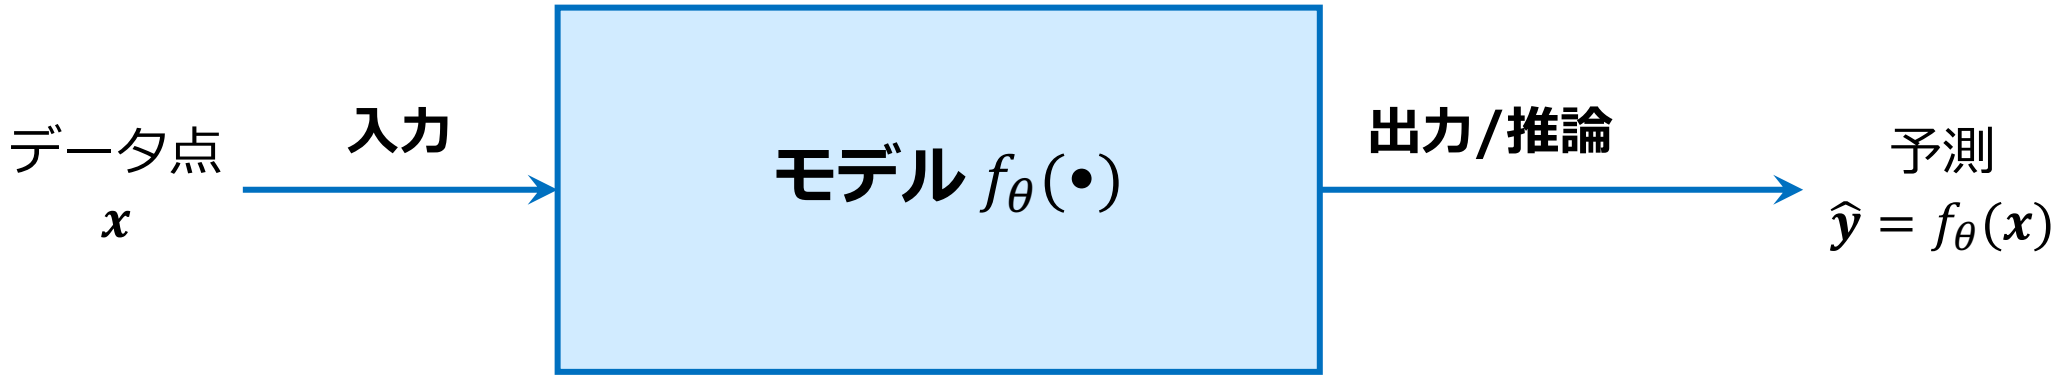


©Yutaka Matsuo. All rights reserved.

機械学習モデルの推論と学習

- 推論：入力 $\boldsymbol{x}$ に対して対応する出力の予測 $\hat{\boldsymbol{y}} = f_\theta(\boldsymbol{x})$ を返す

- 学習：出力の予測 $\hat{\boldsymbol{y}}$ が期待する結果に近づくようにモデルを調整する
  - モデル f_θ の予測 $\hat{\boldsymbol{y}}$ と正解は必ずしも一致しない
  - 学習済みのモデル f_θ の予測 $\hat{\boldsymbol{y}}$ は正解に近くなることが期待される

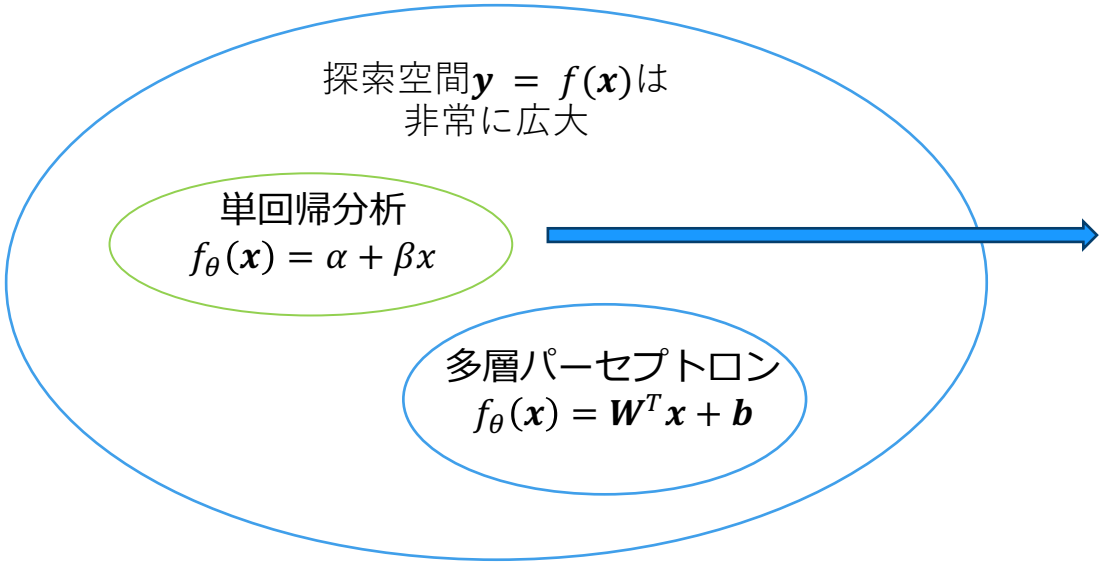


©Yutaka Matsuo. All rights reserved.

機械学習はモデル探索

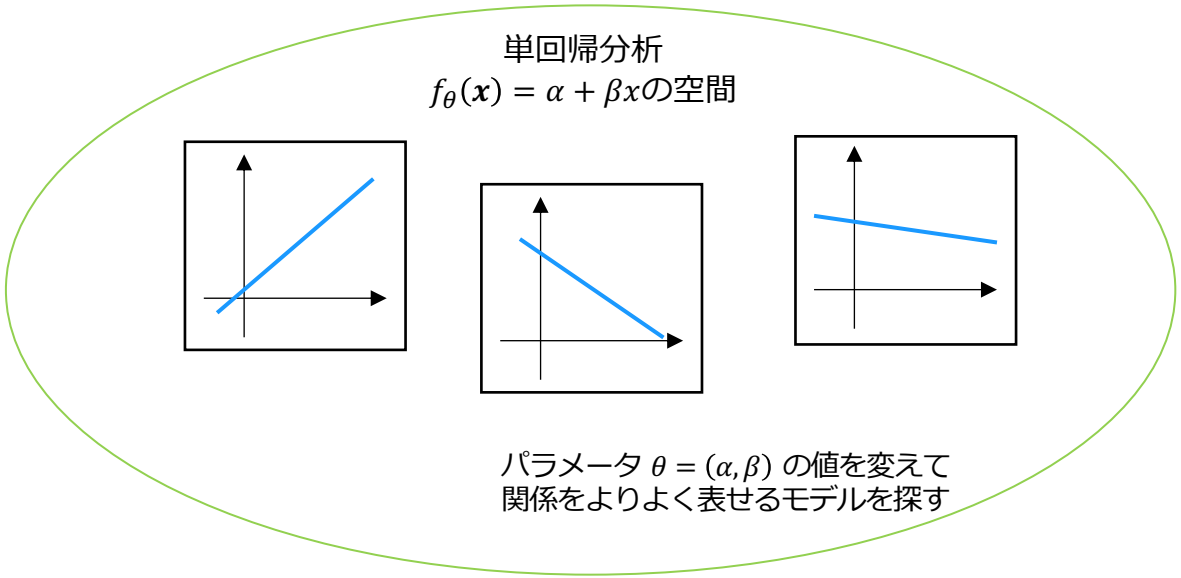
- 学習とは入出力$(\boldsymbol{x}, \boldsymbol{y})$ の関係 $\boldsymbol{y} = f(\boldsymbol{x})$ をよりよく表せる関数 f の探索である
- 探索空間を有限にするために，モデルをパラメトリック(*)に記述して**探索対象とする関数の空間(範囲)**を限定し，パラメータを調整することで探索を行う

① 探索空間を限定
まずハイパーパラメータを設定することによって
モデル f_θを選択し、探索空間を狭める



関係 $\boldsymbol{y} = f(\boldsymbol{x})$ をよく表せる関数が見つかりそうな
モデル f_θ を選択することが重要

② パラメータを調整
モデル f_θを選択した後は，最も妥当な
パラメータ $\boldsymbol{\theta}$ をデータに基づいて探す（学習）



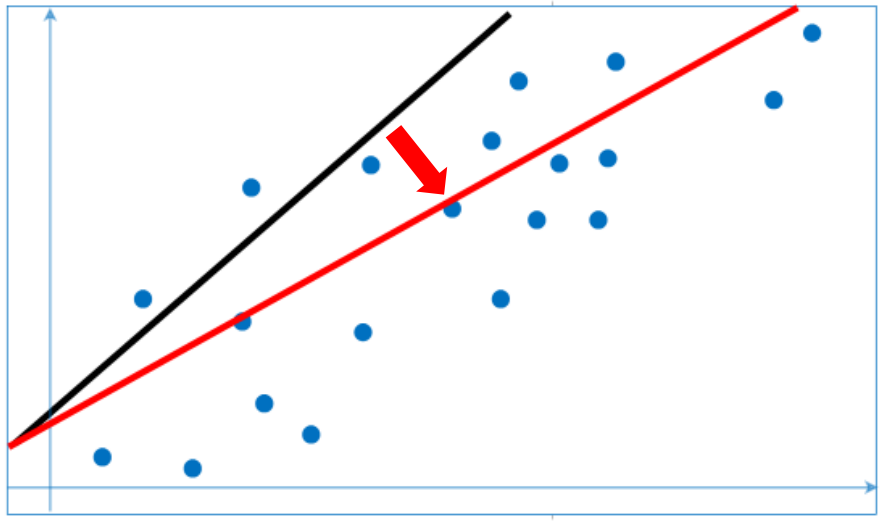
(*) パラメータによって記述されるモデルをパラメトリックモデル（Parametric Model）と呼ぶ
パラメータを用いて記述されないモデルはノンパラメトリックモデル（Nonparametric Model）と呼ぶ

©Yutaka Matsuo. All rights reserved.

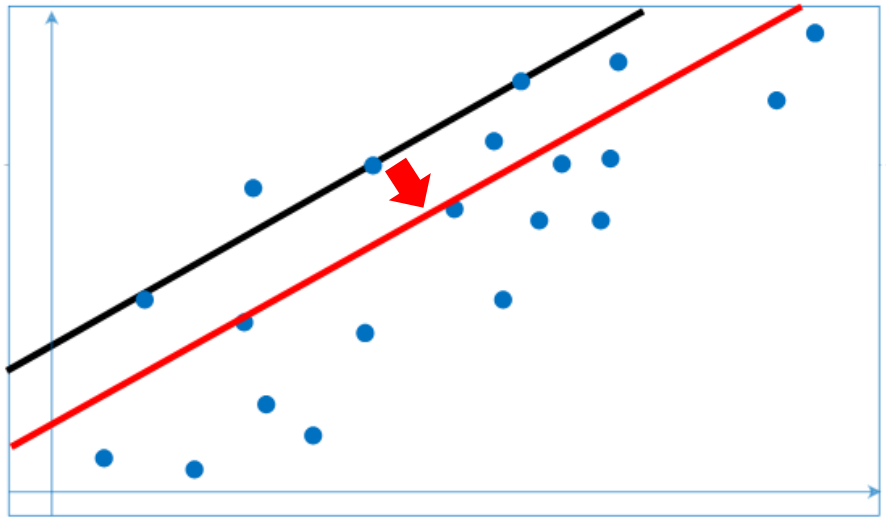
機械学習モデルのパラメータ

- **パラメータ（Parameter）**
  - パラメータは学習によって更新していく変数．予測精度を上げるために，パラメータの最適化を目指す
  - 単回帰分析の式 $y = \alpha + \beta x$ の場合 α (バイアス)，β (重み) がパラメータに相当
    - **重み（Weight）**は入力データの影響度を決め，**バイアス（Bias）**は基準値を決めている

重みが最適化されていない場合(黒線),
最適化された直線(赤線)を目指して重みを更新



バイアスが最適化されていない場合(黒線),
最適化された直線(赤線)を目指してバイアスを更新

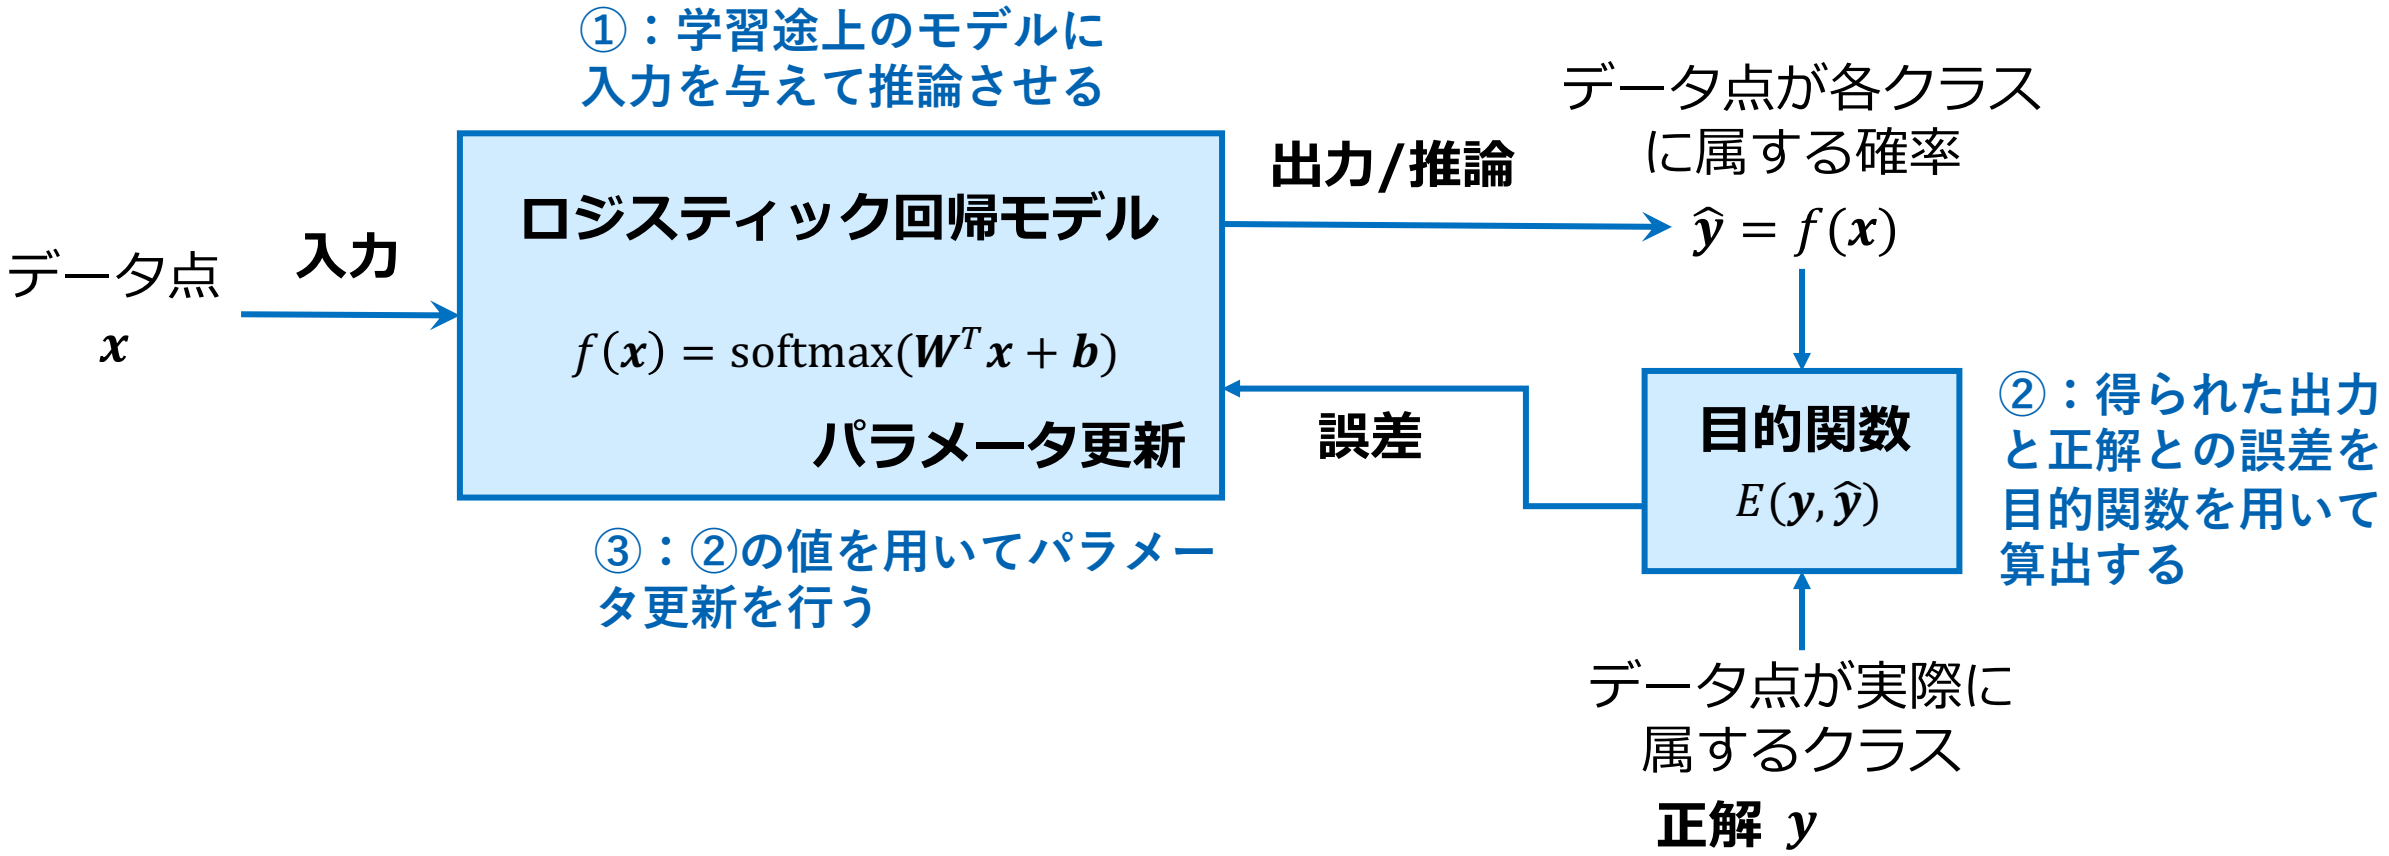


©Yutaka Matsuo. All rights reserved.

機械学習モデルの学習過程

機械学習では，モデルの予測と正解の誤差が小さくなるように
以下の①～③のサイクルを繰り返して調整を行う

例：ロジスティック回帰モデルの学習過程（パラメータ更新の詳細については講義後半）



©Yutaka Matsuo. All rights reserved.

目的関数の例

- **平均二乗誤差 (Mean Squared Error ; MSE)**
  - 正解値 $\boldsymbol{y}$ と予測値 $\hat{\boldsymbol{y}} = f_\theta(\boldsymbol{x})$ の差（誤差）の二乗平均
  - $\boldsymbol{y}$ が実数値を取るとき（回帰問題など）に使われる

$$E(\boldsymbol{y}, \hat{\boldsymbol{y}}) = \frac{1}{N}\sum_{n=1}^{N}(\hat{\boldsymbol{y}}_n - \boldsymbol{y}_n)^2 \qquad N：データ数$$

- **二乗平均平方根誤差 (Root Mean Squared Error ; RMSE)**
  - 平均二乗誤差（MSE）の平方根
  - 誤差の二乗をとるMSEに対し，平方根をとることで単位を元のデータ $\boldsymbol{y}$ と一致させられるため，誤差の大きさを直感的に把握しやすい

$$E(\boldsymbol{y}, \hat{\boldsymbol{y}}) = \sqrt{\frac{1}{N}\sum_{n=1}^{N}(\hat{\boldsymbol{y}}_n - \boldsymbol{y}_n)^2} \qquad N：データ数$$

©Yutaka Matsuo. All rights reserved.

目的関数の例

• クロスエントロピー誤差（Cross Entropy Error）

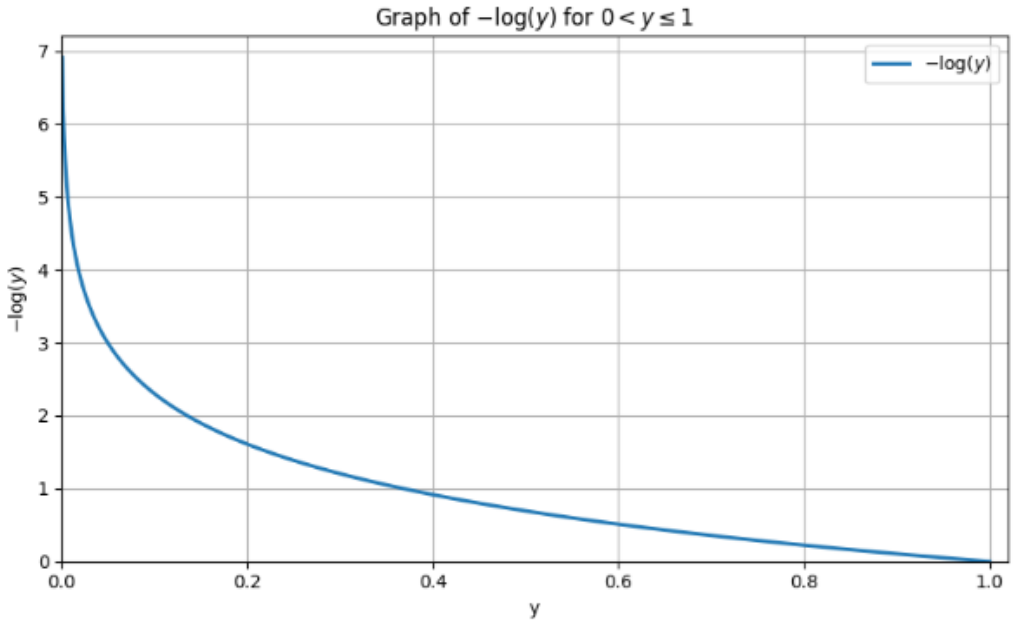
- 正解クラス$k_{correct}$ に対する予測確率 $\hat{y}_{k_{correct}}$が高いと値が小さくなる
  - つまり、正しく予想すればするほど値が小さくなる関数
- y_k が $\{0, 1\}$ の2値をとるとき（ K クラス分類問題など）に使われる（詳細は後述）

N：データ数　K：クラス数

$$E(\boldsymbol{y}, \hat{\boldsymbol{y}}) \equiv -\sum_{n=1}^{N}\sum_{k=1}^{K} y_{nk} \log \hat{y}_{nk}$$

正解ラベルy_{nk}は、任意の$n(1 \leq n \leq N)$において，
kが正解の場合のみ1，その他の場合は0となる

したがって，kが正解の場合の$\hat{y}_{nk}$の値が1に近いと，$\log \hat{y}_{nk}$の値が0に近くなり，結果としてクロスエントロピー誤差が0に近くなる



©Yutaka Matsuo. All rights reserved.

目次

- 機械学習の概要
  - 導入，応用事例の紹介
- 機械学習モデル
  - モデルとは何か
  - 学習と推論
  - **教師あり学習**
    - 分類問題，回帰問題
- 機械学習モデルの評価・選択
- ロジスティック回帰

©Yutaka Matsuo. All rights reserved.

機械学習の分類

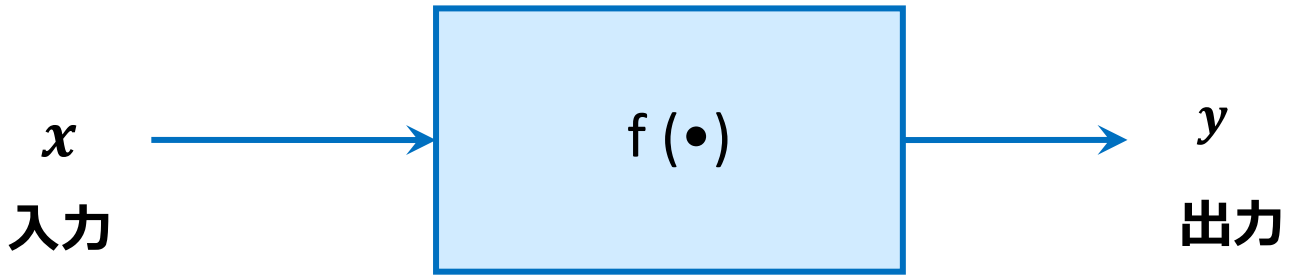
- **教師あり学習（Supervised Learning）**
  - データ集合 $\mathcal{D}$ $=\{(\boldsymbol{x}_1,\boldsymbol{y}_1),\cdots,(\boldsymbol{x}_n,\boldsymbol{y}_n)\}$ のデータペアの対応関係 $\boldsymbol{y}=f(\boldsymbol{x})$ を推定する
- **教師なし学習（Unsupervised Learning）**
  - データ集合 $\mathcal{X}$ $=\{\boldsymbol{x}_1,\cdots,\boldsymbol{x}_n\}$ の構造を同定する
- **強化学習（Reinforcement Learning ; RL）**
  - 得られる報酬を最大化するような行動を選択するモデルを構築する

©Yutaka Matsuo. All rights reserved.

教師あり学習とは

- 教師あり学習
  - 入出力データのペア $(\boldsymbol{x}, \boldsymbol{y})$ の対応関係を推定する問題
  - 入力 $\boldsymbol{x}$ を説明変数，出力 $\boldsymbol{y}$ を目的変数と呼ぶ

- 新しい入力 $\boldsymbol{x}$ に対応する出力 $\boldsymbol{y}$ を推論したい
  - 新しいペア $(\boldsymbol{x}, \boldsymbol{y})$ もデータ集合 $\mathcal{D}$ と同様の関係 f に従うと考える
  - 各 $(\boldsymbol{x}, \boldsymbol{y}) \in \mathcal{D}$ の $\boldsymbol{y}$ を最もうまく表現できる**関数（function ; f）**を見つける



©Yutaka Matsuo. All rights reserved.

教師あり学習の種類

- **分類問題（Classification）**
  - 入力 $\boldsymbol{x}$ から（有限個の）離散値出力 $\boldsymbol{y}$ を推定する問題

- **回帰問題（Regression）**
  - 入力 $\boldsymbol{x}$ から連続値出力 y を推定する問題

©Yutaka Matsuo. All rights reserved.

教師あり学習｜分類問題

- 分類問題
  - 入力 $\boldsymbol{x}$ から（有限個の）離散値出力 $\boldsymbol{y}$ を推定する問題

- 二値分類と多値分類で区別して扱うことも多い
  - 二値分類：入力 $\boldsymbol{x}$ があるクラスに属するか属さないかを判別する
  - 多値分類：入力 $\boldsymbol{x}$ が K 種類のクラスのいずれに属するかを判別する
    - 二値分類は多値分類の特別な場合になっている

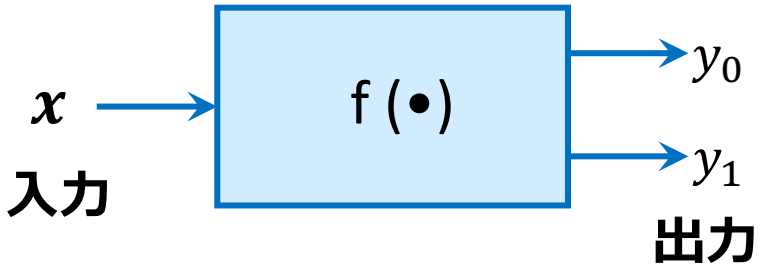
©Yutaka Matsuo. All rights reserved.

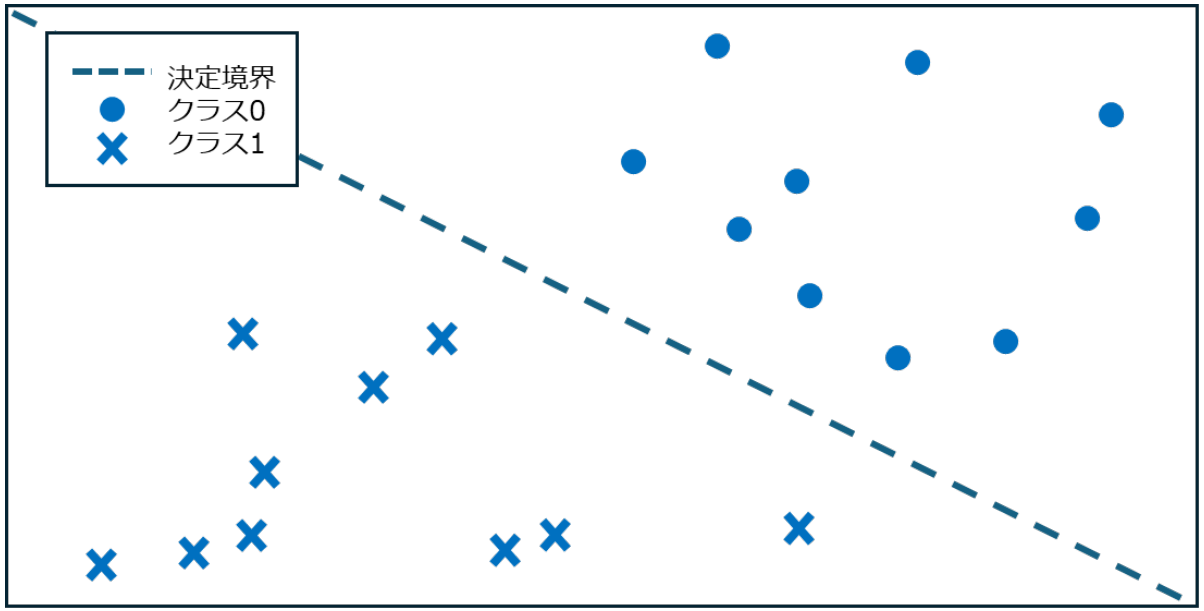
教師あり学習｜分類問題

- **二値分類問題（Binary Classification）**
  - 入力 x があるクラスに属するか属さないかを判別する問題

- 適用可能な機械学習モデル例
  - ロジスティック回帰
  - サポートベクトルマシン（SVM）
  - 決定木・ランダムフォレスト
  - 深層学習

ロジスティック回帰・深層学習による分類の例
クラス0, クラス1である確率を出力する





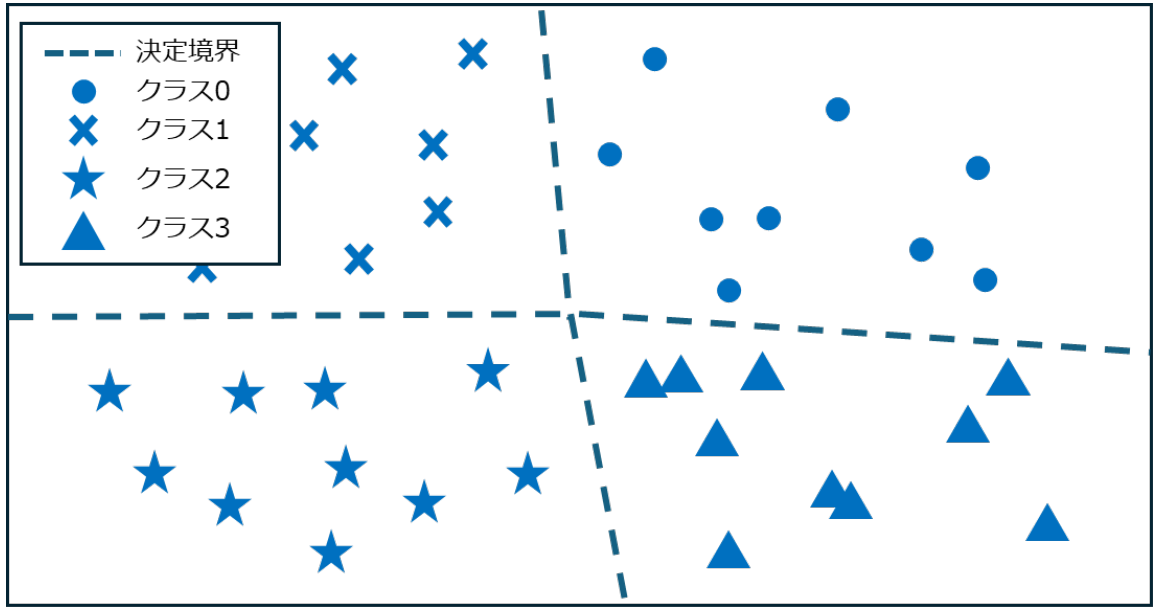
2値分類のデータ空間上でのイメージ

©Yutaka Matsuo. All rights reserved.

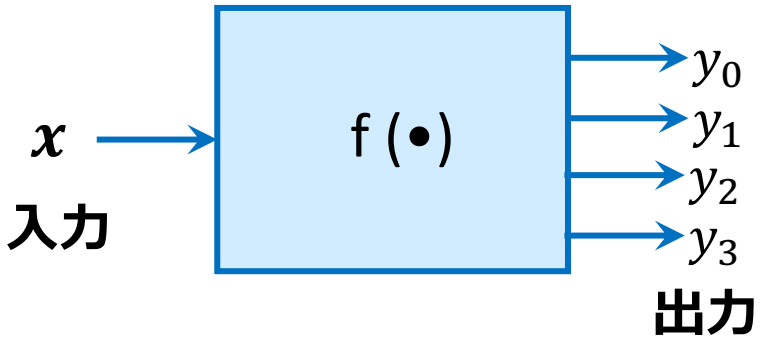
教師あり学習｜分類問題

- **多値分類問題（Multi-class Classification）**
  - 入力 $\boldsymbol{x}$ が K 種類のクラスのいずれに属するかを判別する問題

- 適用可能な機械学習モデル例
  - ロジスティック回帰
  - 決定木・ランダムフォレスト
  - 深層学習



ロジスティック回帰・深層学習による分類の例
クラス0, 1, 2, 3である確率を出力する

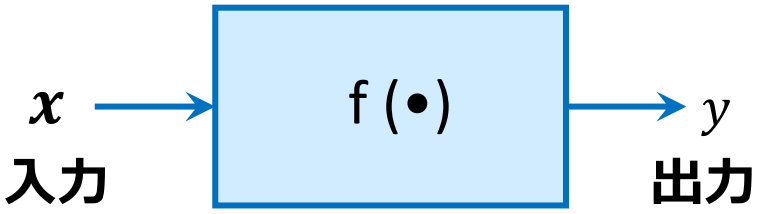


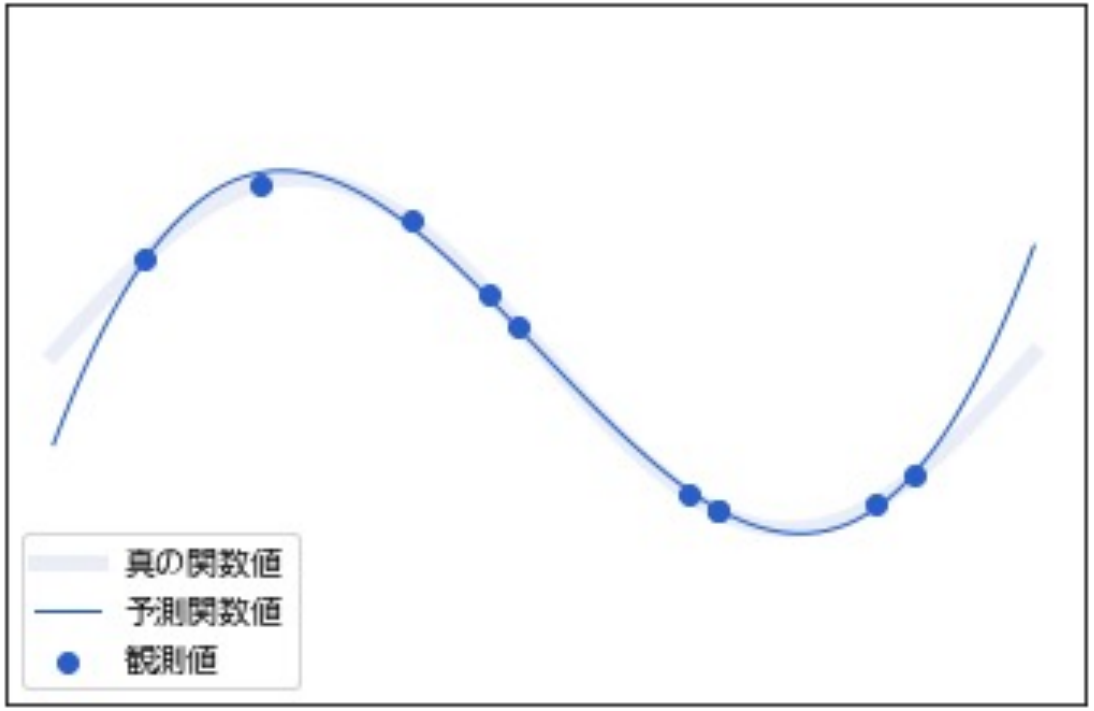
©Yutaka Matsuo. All rights reserved.

教師あり学習｜回帰問題

- 回帰問題
  - 入力 x から連続値出力 y を推定する問題
  - 具体例：株価予測，製造業の実験計画法

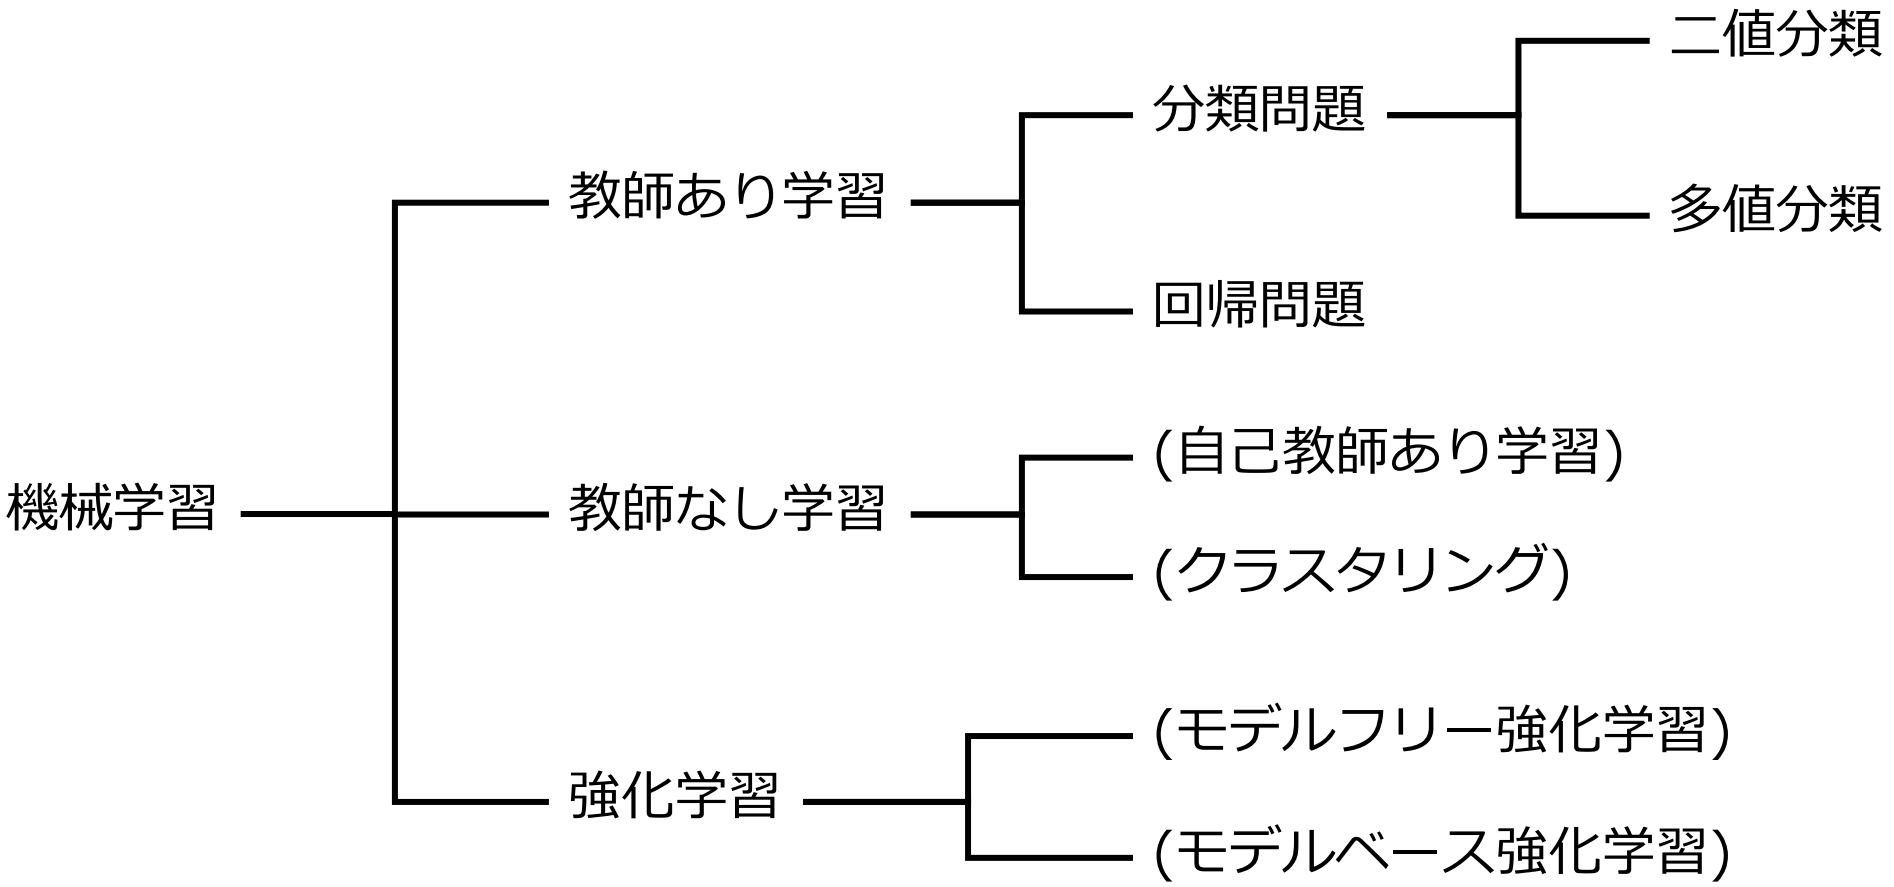
- 適用可能な機械学習モデル例
  - 線形回帰
  - ガウス過程回帰
  - 決定木回帰・ランダムフォレスト回帰
  - 深層学習





©Yutaka Matsuo. All rights reserved.

機械学習の分類まとめ



免責：
- 括弧付きは本講義回では取り扱いなし
- 分類はあくまでも一例
- 記載ない種類もある

©Yutaka Matsuo. All rights reserved.

目次

- 機械学習の概要
  - 導入，応用事例の紹介
- 機械学習モデル
  - モデルとは何か
  - 学習と推論
  - 教師あり学習
    - 分類問題，回帰問題
- **機械学習モデルの評価・選択**
- ロジスティック回帰

©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

- 機械学習モデルは適切に評価する必要がある
  - 「どのモデルを採用するか決めたい」
  - 「そのモデルがどの程度妥当な判断をするか確認したい」

- どんなデータに対しても妥当な判断をするモデルが良い
  - 学習に使ったデータだけでなく，学習に使わなかったデータに対する性能も高いことが望ましい

©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

- **汎化性能（Generalization Performance）**
  - 学習に使用していない未知のデータに対する予測性能

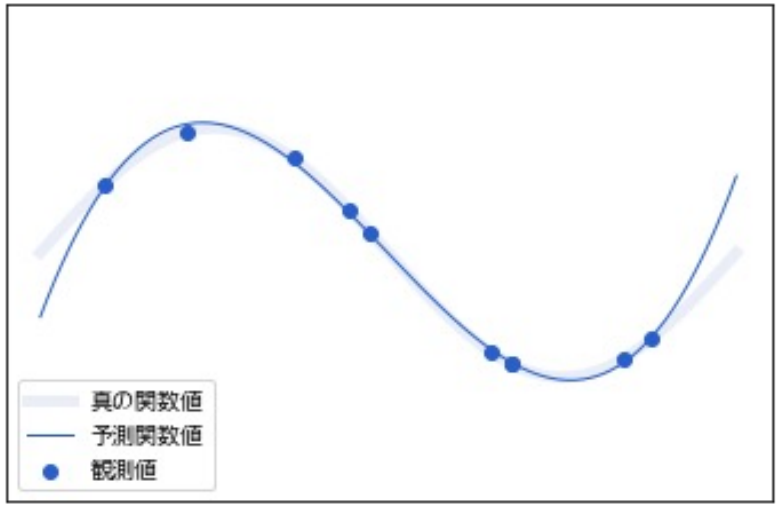
- 汎化性能が高いものが「良いモデル」である
  - データのとり得る値として膨大な種類が考えられるが，
    そのすべてを学習データとして与えることは現実的ではない
  - 汎化性能が高いモデルはデータに含まれる普遍的な性質を捉えていると考えられる

©Yutaka Matsuo. All rights reserved.

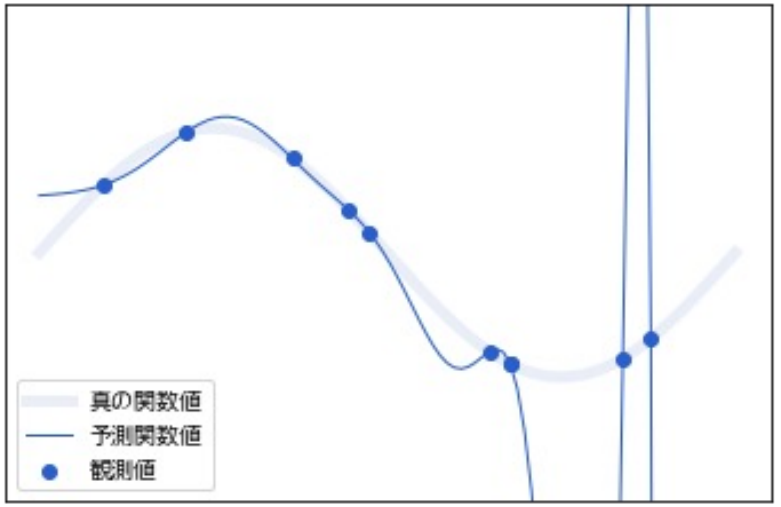
機械学習モデルの評価

- **過学習（Overfitting）**
  - 学習のためのデータに過剰にフィットし，未知のデータの予測性能が低下する現象
  - 例： 三角関数の多項式回帰問題（データ集合のサイズ $N = 10$）
    - 事前に決定するモデルの次数（モデルの複雑さ）によって，過学習の発生のしやすさが変わる
    - 次数のように学習前に決めるモデルのパラメータを**ハイパーパラメータ（Hyper Parameter）**という

多項式の次数 $d = 3$



多項式の次数 $d = 15$



©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

- 過学習の具体的なイメージ

問題集を解いて丸暗記する



問題集は解けるがテストでは･･･



テストの結果は良くならない･･･



©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

- 過学習の原因例
  - 学習のためのデータが少ない
  - データ数に対してモデルが複雑すぎる
    - モデルのパラメータ数が多いなど

- 過学習の対策例
  - データを増やす
  - 複雑すぎないモデルを使う
  - パラメータに制約を設ける (詳しくは第4回を参照)

©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

- 過学習の具体的な**対策**のイメージ

問題集の数をもっと増やす



参考書などで要点を押さえた学習をする



過学習を押さえた結果は･･･



テストの結果が良くなる！

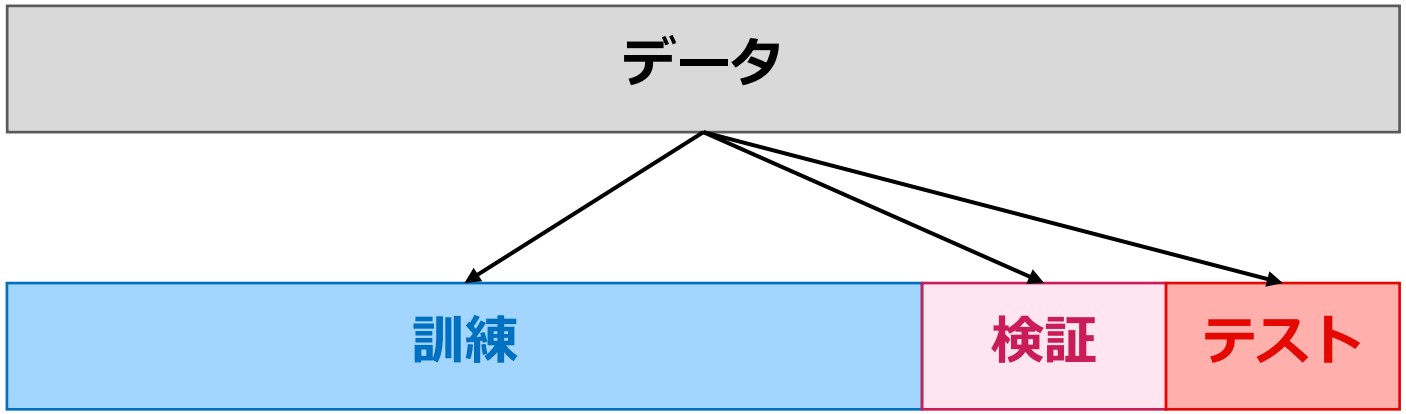


©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

データを3つに分割する

- **訓練データ**：モデルの学習に使用する
- **検証データ**：モデルの評価に使用する
- **テストデータ**：選択したモデルの最終的な評価に使用する



©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

検証データとテストデータの扱いの違い

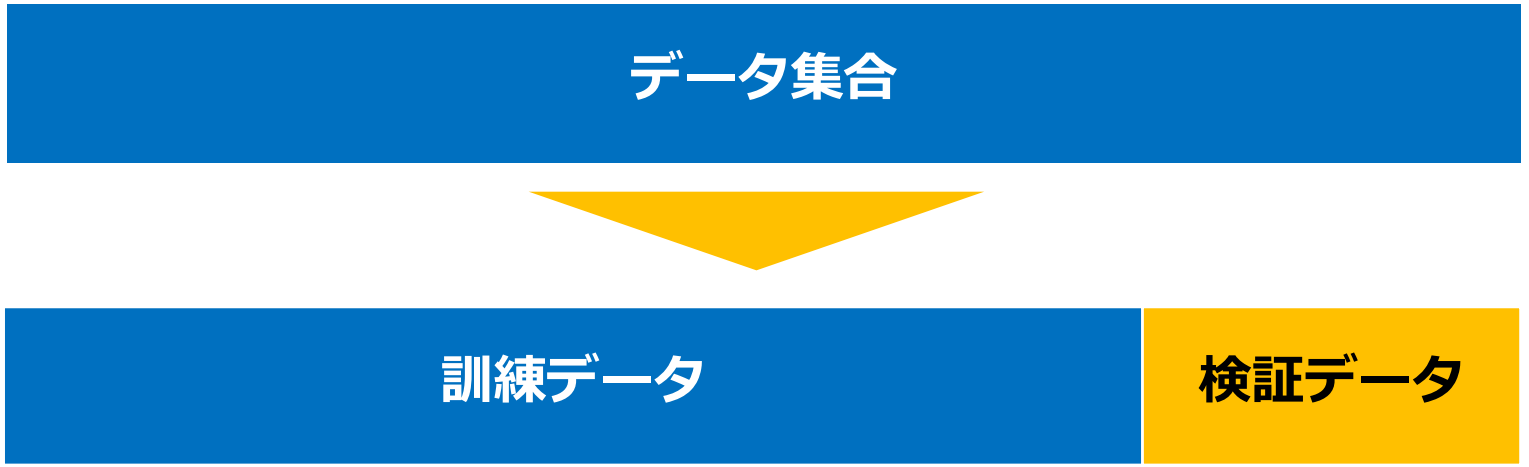
- 検証データ
  - 訓練データで学習したモデルの（汎化）性能の評価に用いる
  - モデルの学習には使用しない

- テストデータ
  - 選択したモデルの最終的な評価に用いる
  - 原則として最後に一度だけ使用する

©Yutaka Matsuo. All rights reserved.

機械学習モデルの評価

- **ホールドアウト検証（Hold out Validation）**
  - 検証データの分け方の一つ
  - データ集合を一定の割合で訓練データと検証データに分け，一回のみ検証を行う



- その他の分け方として**（k分割）交差検証（Cross Validation）**などがある
  （詳細は補足を参照）

©Yutaka Matsuo. All rights reserved.

性能指標

- **混同行列 (Confusion Matrix)**
  - モデルの予測の正誤をその種類ごとに表したもの

	負例(予測結果)	**正例(予測結果)**
負例(正解)	True Negative (TN)	False Positive (FP)
正例(正解)	False Negative (FN)	True Positive (TP)

二値分類タスクの場合の混同行列

©Yutaka Matsuo. All rights reserved.

性能指標

- **正解率 (Accuracy)**：$(TP + TN) / (TP + TN + FP + FN)$
  - 一般的に（比較的よく）使われている指標

- **適合率 (Precision)** ：$TP / (TP + FP)$
  - モデルがpositiveと予測したデータ点のうち，実際にpositiveであったものの割合

- **再現率 (Recall)** ：$TP / (TP + FN)$
  - 実際にpositiveであるデータ点のうち，モデルがpositiveと予測できたものの割合

- **F値（F-Score）** ：$2 \times precision \times recall / (precision + recall)$
  - 適合率と再現率の調和平均

©Yutaka Matsuo. All rights reserved.

モデル選択

- 機械学習モデルの候補は複数考えられる

- どのモデルが適合するかはデータに依存するところが大きいため，事前に見定めることは難しい
  - 実際に学習させた結果に基づいて最良のモデルを選択したい

©Yutaka Matsuo. All rights reserved.

モデル選択

1.データ集合 $\mathcal{D}$ およびモデル候補集合 $\mathcal{F}$ を準備する

2.データ集合 $\mathcal{D}$ を3つに分割する
$\mathcal{D}_{train}$：訓練データ，$\mathcal{D}_{valid}$：検証データ，$\mathcal{D}_{test}$：テストデータ

3.各モデル $f \in \mathcal{F}$ に対して以下を実行する：

a.訓練データ $\mathcal{D}_{train}$ を使ってモデル f を学習させる

b.検証データ $\mathcal{D}_{valid}$ を使ってモデル f の（汎化）性能を評価する

4.最良のモデル f^* を選択する

5.テストデータ $\mathcal{D}_{test}$ を使って f^* を評価する

©Yutaka Matsuo. All rights reserved.

目次

- 機械学習の概要
  - 導入，応用事例の紹介
- 機械学習モデル
  - モデルとは何か
  - 学習と推論
  - 教師あり学習
    - 分類問題，回帰問題
- 機械学習モデルの評価・選択
- **ロジスティック回帰**

©Yutaka Matsuo. All rights reserved.

実装例：ロジスティック回帰 on MNIST

- データセット：**MNIST（Modified National Institute of Standards and Technology database）**
  - 演習資料の前処理について
- 問題：多クラス分類問題
- 機械学習アルゴリズム：ロジスティック回帰
  - ロジスティック回帰モデルの学習と推論

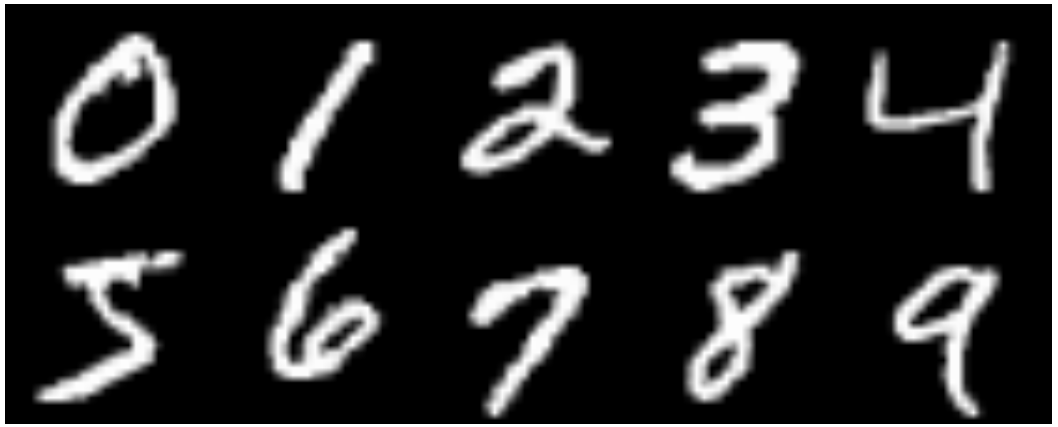
©Yutaka Matsuo. All rights reserved.

データセット：MNIST

- MNIST：手書き数字 (0-9) の画像データセット

  - データセットのサイズ
    - 訓練データ：60000枚 (0-9 各6000枚)
      テストデータ：10000枚 (0-9 各1000枚)

  - 画像
    - 画素数：28 * 28 ピクセル (2次元画像)
      画素値：グレースケール (0 – 255)

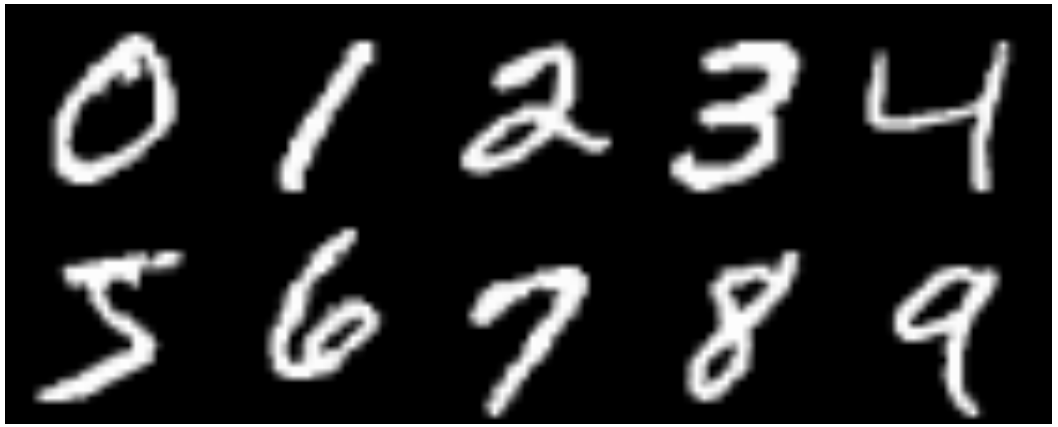


©Yutaka Matsuo. All rights reserved.

データセット：MNIST

- MNIST：手書き数字 (0-9) の画像データセット

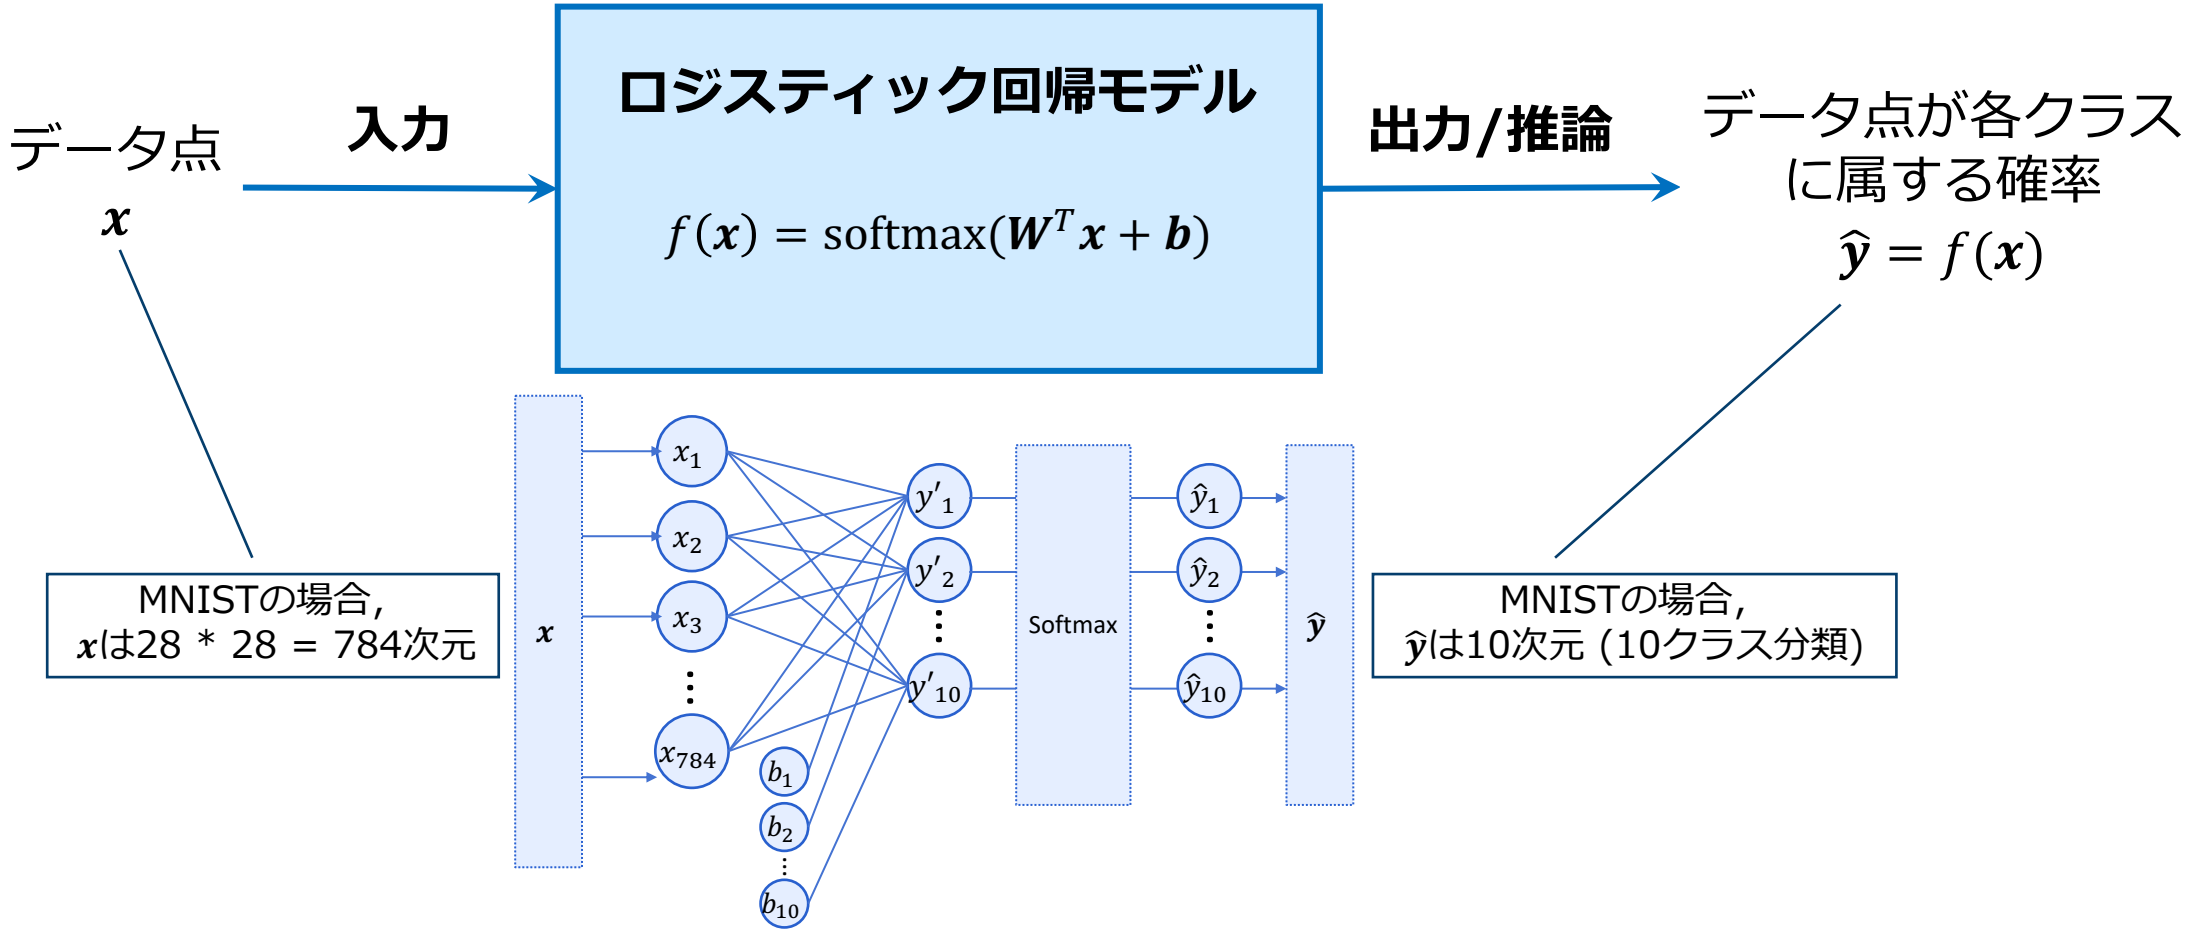
  - (演習資料における) 前処理
    - 画素値のスケーリング
      0 – 255 (整数) → 0.0 – 1.0 (浮動小数点数)
    - 正解クラスラベル (0–9) を **One-hot ベクトル （One-hot Vector）**に変換
      例：2 → [0, 0, 1, 0, 0, 0, 0, 0, 0, 0]
    - 画素の平坦化
      28 * 28 (2次元画像) → 784 (1次元画像)



©Yutaka Matsuo. All rights reserved.

問題設定：多値分類問題

- 多値分類問題



©Yutaka Matsuo. All rights reserved.

問題設定：多値分類問題

- 多値分類問題



入力

ロジスティック回帰モデル

$$f(\boldsymbol{x}) = \mathrm{softmax}(\boldsymbol{W}^T\boldsymbol{x} + \boldsymbol{b})$$

出力/推論

0： 0.00
1： 0.10
2： 0.00
3： 0.00
4： 0.60
5： 0.00
6： 0.05
7： 0.10
8： 0.00
9： 0.15

予測：[0.00, 0.10, 0.00, 0.00, **0.60**, 0.00, 0.05, 0.10, 0.00, 0.15]

正解に近づけるよう学習

正解：[0, 0, 0, 0, **1**, 0, 0, 0, 0, 0]

©Yutaka Matsuo. All rights reserved.

機械学習モデル：ロジスティック回帰

- モデル：**ロジスティック回帰（Logistic Regression）**

$$\boldsymbol{y} = \underbrace{\mathrm{softmax}}_{\text{活性化関数}}(\underbrace{\boldsymbol{W}^T\boldsymbol{x} + \boldsymbol{b}}_{\text{線形変換}})$$

$$\boldsymbol{x} \in \mathbb{R}^{D_{in}}, \boldsymbol{y} \in \mathbb{R}^{D_{out}}, \boldsymbol{W} \in \mathbb{R}^{D_{in} \times D_{out}}, \boldsymbol{b} \in \mathbb{R}^{D_{out}}$$

D_{in}: 入力ベクトルの次元, D_{out}: 出力ベクトルの次元

- 分類問題を解く（≠回帰問題）
  - 入力データが各クラスに属する確率を出力する
  - 線形関数では，直線や平面しか表現できない

    →**活性化関数（Activation Function）**によって直線ではない非線形の表現が出来るようになる
  - 上式では活性化関数としてソフトマックス関数を適用している

©Yutaka Matsuo. All rights reserved.

機械学習モデル：ロジスティック回帰

• ソフトマックス関数（Softmax Function）

$$y_k = \mathrm{softmax}(\boldsymbol{x})_k \equiv \frac{\exp(x_k)}{\sum_{k=1}^{K} \exp(x_k)}$$

$$\boldsymbol{x} \in \mathbb{R}^K, \boldsymbol{y} \in [0,1]^K$$

	ソフトマックス前	ソフトマックス後
たぬき	2.0	0.659
アライグマ	1.0	0.242
ハクビシン	0.1	0..099
合計	3.0	1.000

最も大きな値を強調しつつ，
合計を1.0とするように変換

- K次元実数値ベクトルをKクラス確率分布に変換する活性化関数
  - 指数関数を適用して正規化を行う
  - 出力値は「入力データがあるクラスに属する確率」であると考える
  - $K = 2$ のときにはシグモイド関数と呼ばれる（詳細は補足を参照）
  - 実装では指数関数のオーバーフローを防ぐために入力の定数シフトなどの対策を講じる

©Yutaka Matsuo. All rights reserved.

機械学習モデル：ロジスティック回帰

- 目的関数：クロスエントロピー誤差

$$E(\boldsymbol{y}, \hat{\boldsymbol{y}}) \equiv -\sum_{n=1}^{N}\sum_{k=1}^{K} y_{nk} \log \hat{y}_{nk}$$

$\boldsymbol{y}_n \in \{0,1\}^K$: データ$n$の正解ラベル, $\hat{\boldsymbol{y}}_n \in [0,1]^K$: データ$n$の予測確率
N: データ数, K: クラス数

- 分類問題の評価指標としてよく用いられる
  - 正解クラス k^* に対する予測確率 $\hat{y}_{k^*}$ を1に近づけたい
    - （正解クラス k^* に予測確率 $\hat{y}_{k^*}$ を割り振っても問題ないように実装では小さな値を加える）

©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の推論

- 各クラスに属する確率 $\hat{\boldsymbol{y}}$ が出力される
  - 入力 $\boldsymbol{x}$ が属するクラスを推定したいときには確率が最大となるクラスを選択すれば良い

$$k^* = \mathrm{argmax}_k \, \hat{y}_k$$

※補足：出力確率 $\hat{\boldsymbol{y}}$ に関して期待値をとることも考えられる

$$E = \mathbb{E}_{\hat{\boldsymbol{y}}}[f(\boldsymbol{x})] = \sum_{k=1}^{K} f(x_k)\hat{y}_k$$

この例では$k^* = 4$

k：	$\hat{y}_k$
0：	0.00
1：	0.10
2：	0.00
3：	0.00
4：	**0.60**
5：	0.00
6：	0.05
7：	0.10
8：	0.00
9：	0.15

©Yutaka Matsuo. All rights reserved.

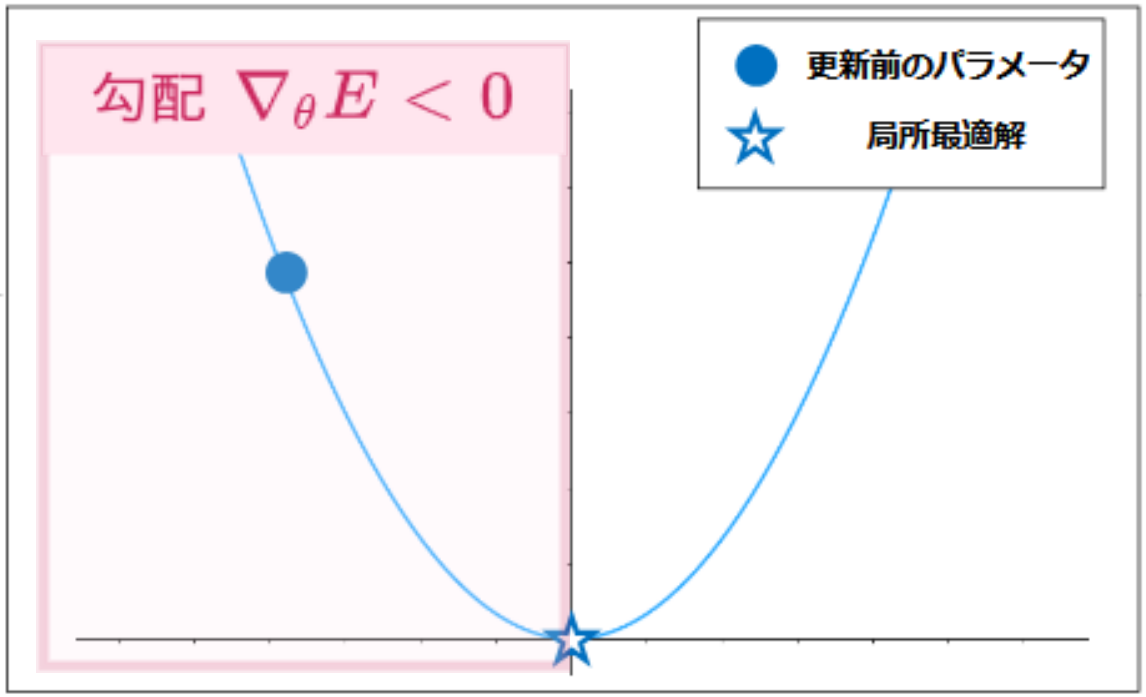
ロジスティック回帰の学習

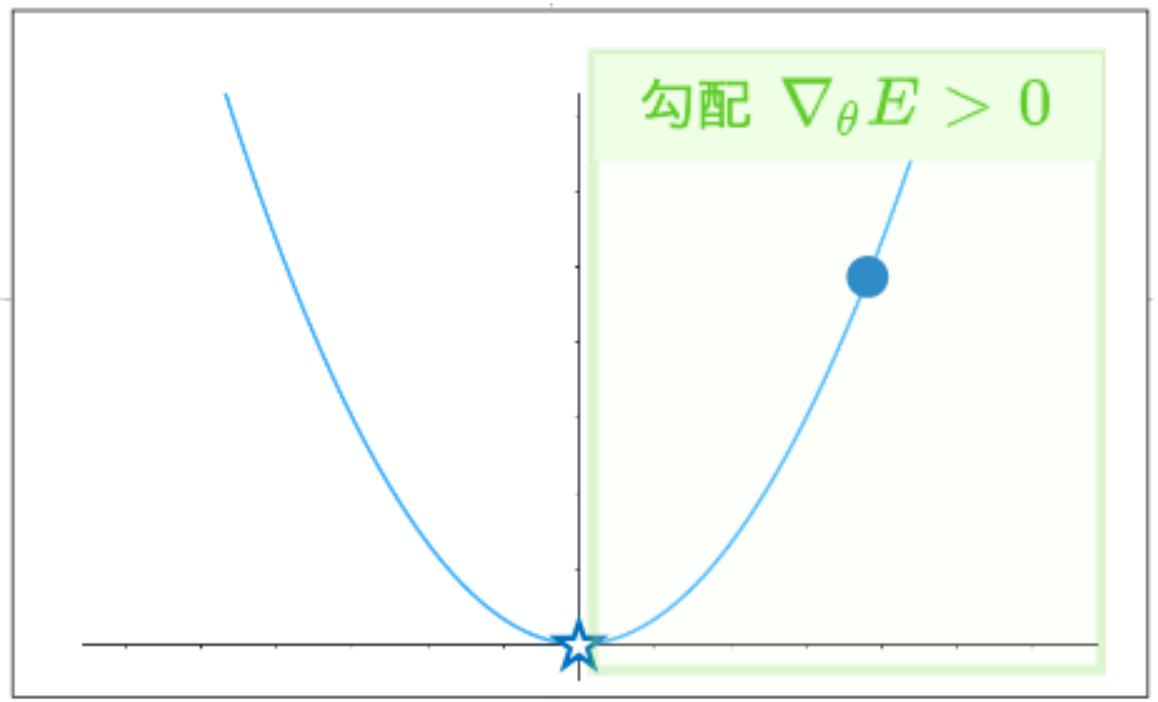
- **勾配降下法（Gradient Descent）**
  - 勾配情報に基づいて目的関数 E を減少させるようにパラメータを更新する
  - 勾配 > 0：パラメータを負の方向に動かせば目的関数が減少する
  - 勾配 < 0：パラメータを正の方向に動かせば目的関数が減少する
  - 勾配 = 0：目的関数値は（局所的に）最小である

©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- 勾配降下法
  - 勾配情報に基づいて目的関数 E を減少させるようにパラメータを更新する

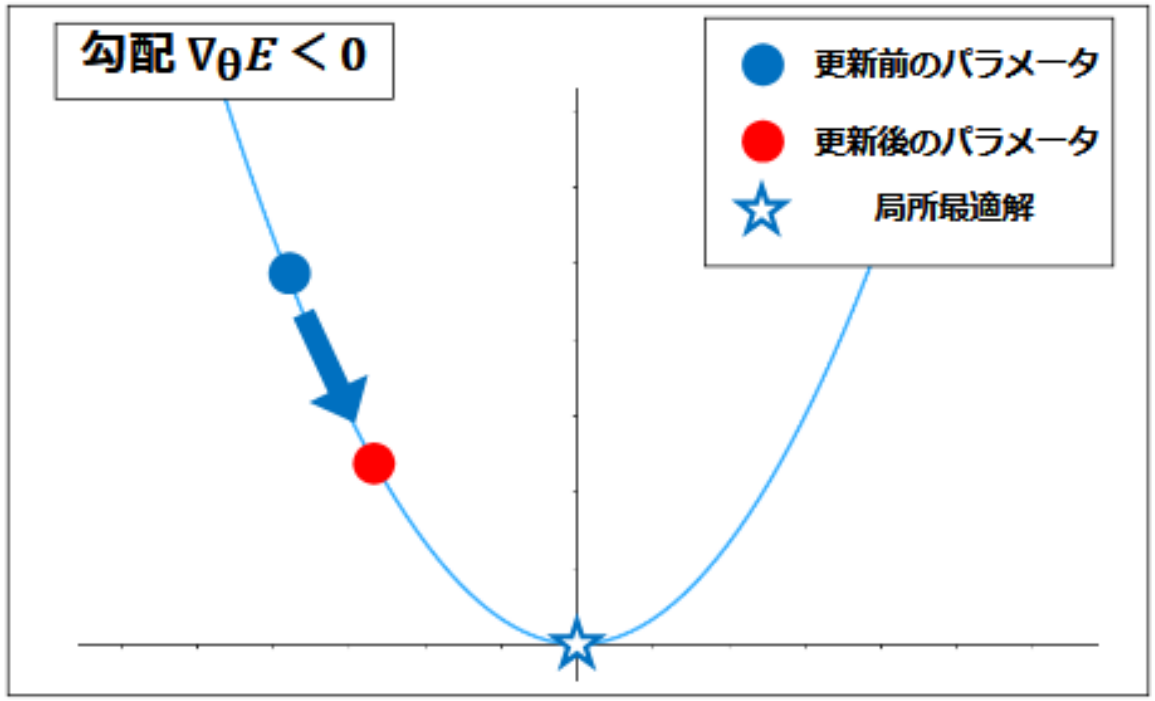


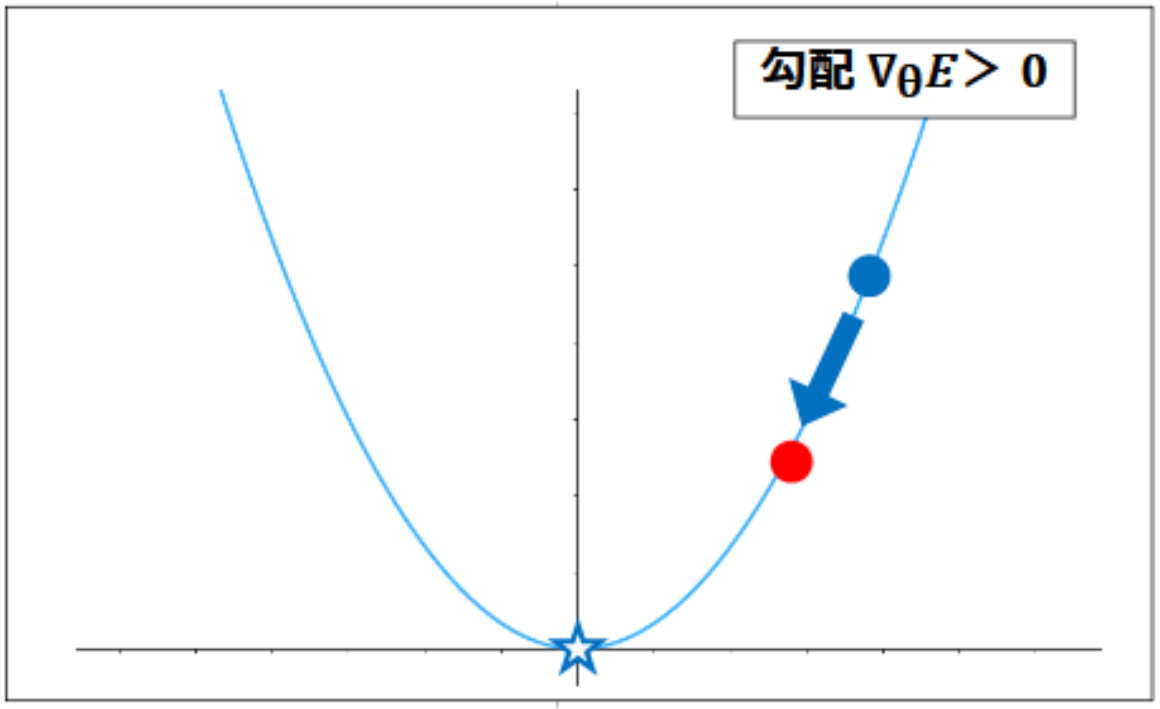


©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- 勾配降下法
  - 勾配情報に基づいて目的関数 E を減少させるようにパラメータを更新する

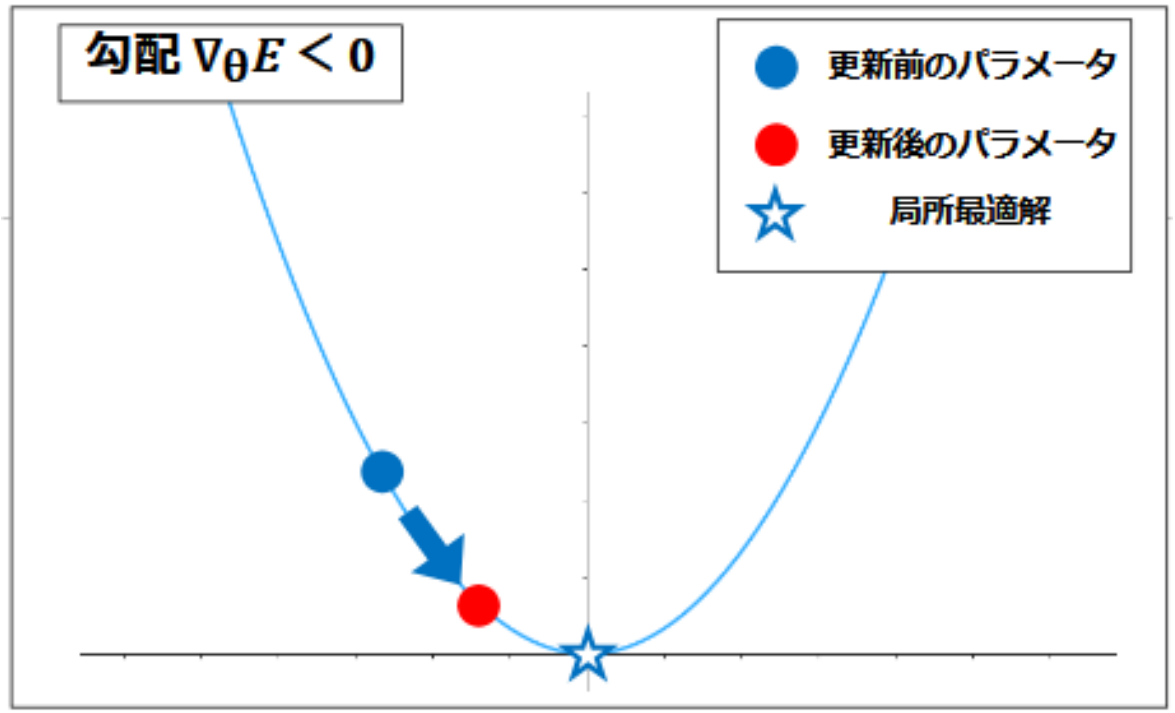


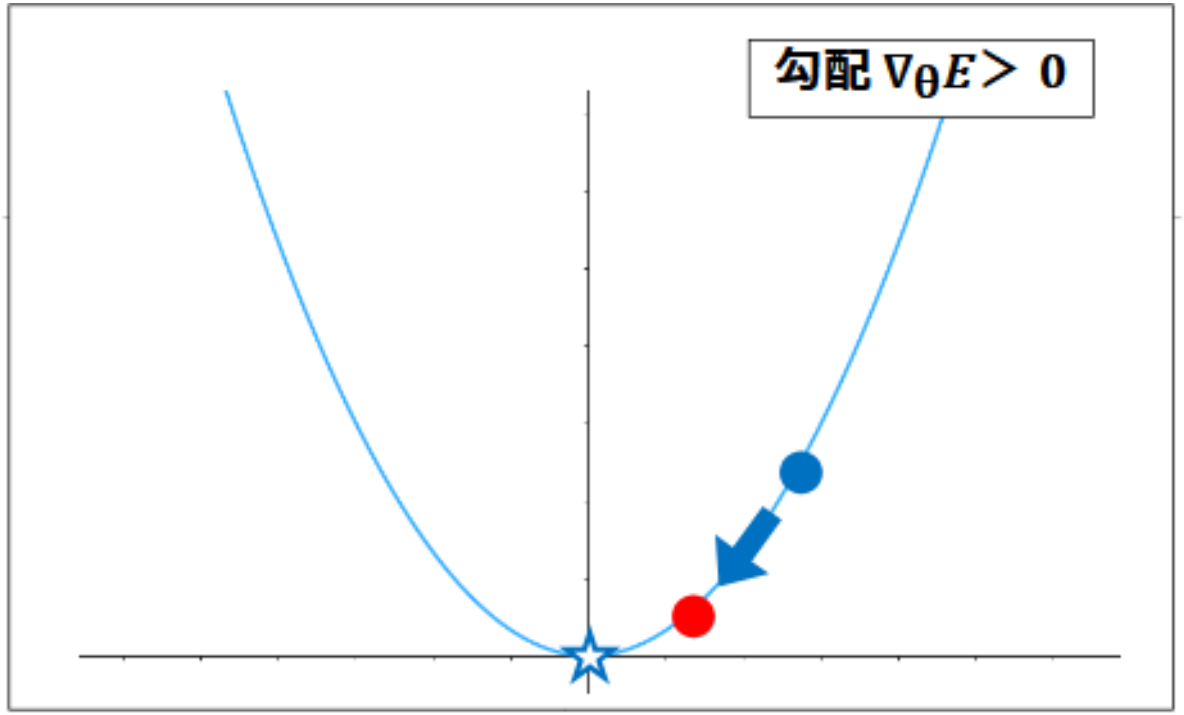


©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- 勾配降下法
  - 勾配情報に基づいて目的関数 E を減少させるようにパラメータを更新する

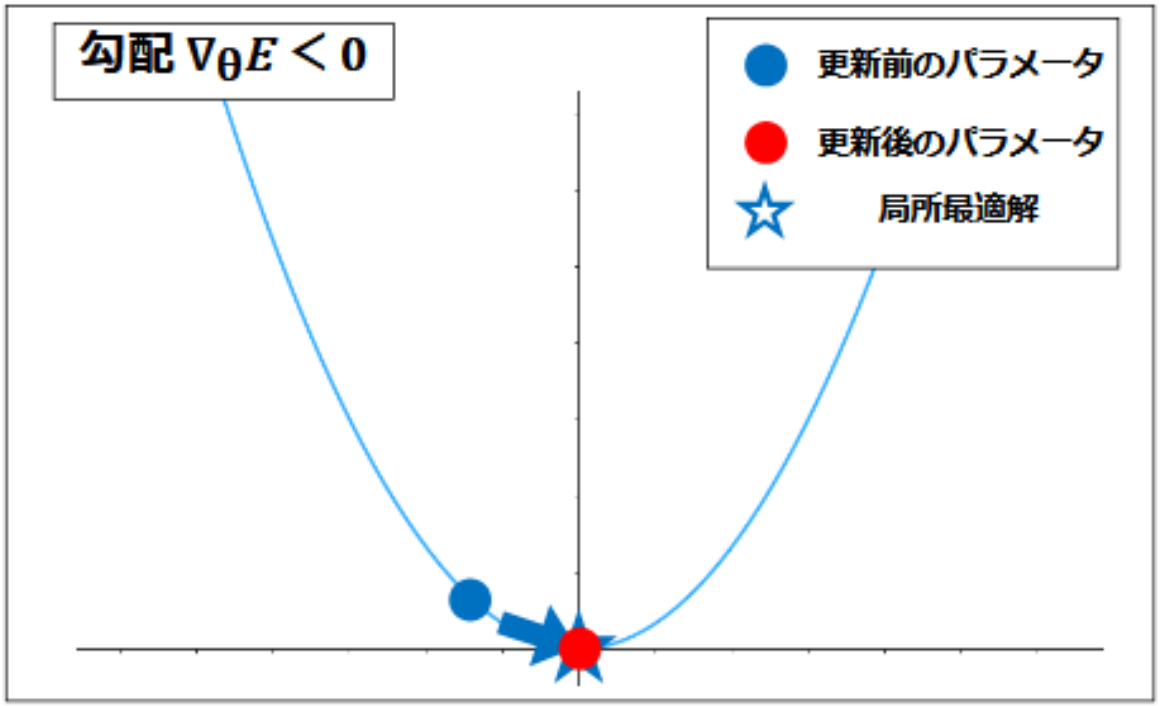


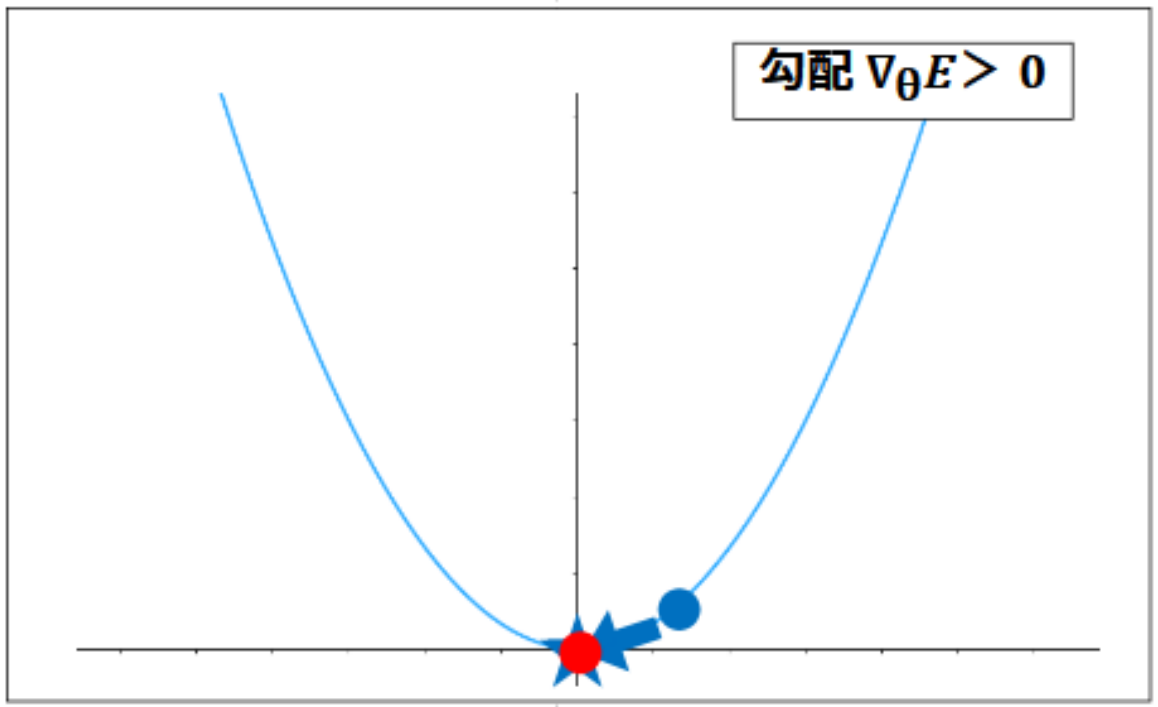


©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- 勾配降下法
  - 勾配情報に基づいて目的関数 E を減少させるようにパラメータを更新する





©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- 勾配降下法
  - 勾配情報に基づいて目的関数 E を減少させるようにパラメータを更新（t は反復回数）

$$w_k^{(t+1)} = w_k^{(t)} - \eta \nabla_{w_k} E\left(w_k^{(t)}\right)$$
$$b_k^{(t+1)} = b_k^{(t)} - \eta \nabla_{b_k} E\left(b_k^{(t)}\right)$$

※青字の部分は省略して表記することもある

- η を**学習率（Learning Rate）**という
  - 学習率を調整することでパラメータの更新量を変えることが出来る
  - 学習率が大きすぎる
    ○ 最適解に近づく速度が早い
    × 値が発散したり収束値の精度が悪化する
  - 学習率が小さすぎる
    ○ 収束値，最適解の精度が良い傾向にある
    × 最適化速度が遅い．過学習しやすい

©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- 勾配降下法
  - クロスエントロピー誤差関数 E の勾配は簡単な式で表現することができる

$$E(\boldsymbol{y}, \hat{\boldsymbol{y}}) \equiv -\sum_{n=1}^{N}\sum_{k=1}^{K} y_{nk} \log \hat{y}_{nk}$$

$$\nabla_{w_k} E(w_k) = -\sum_{n=1}^{N} (y_{nk} - \hat{y}_{nk})\, x_n$$

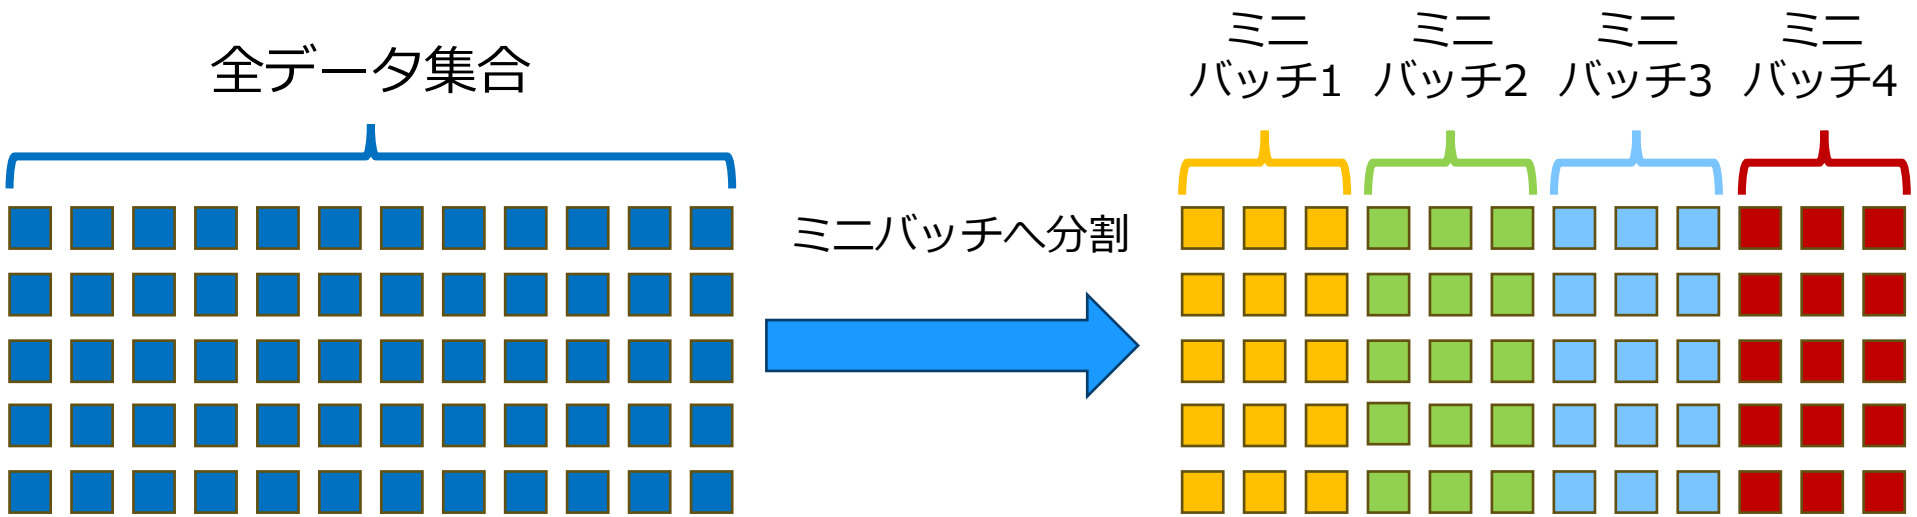
$$\nabla_{b_k} E(b_k) = -\sum_{n=1}^{N} (y_{nk} - \hat{y}_{nk})$$

©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- **ミニバッチ勾配降下法（Mini-batch Gradient Descent）**
  - **バッチ（Batch）**とは，データ集合のこと
    - **バッチサイズ（Batch Size）**が大きい場合(1億枚の画像など)，勾配の計算が大変になる

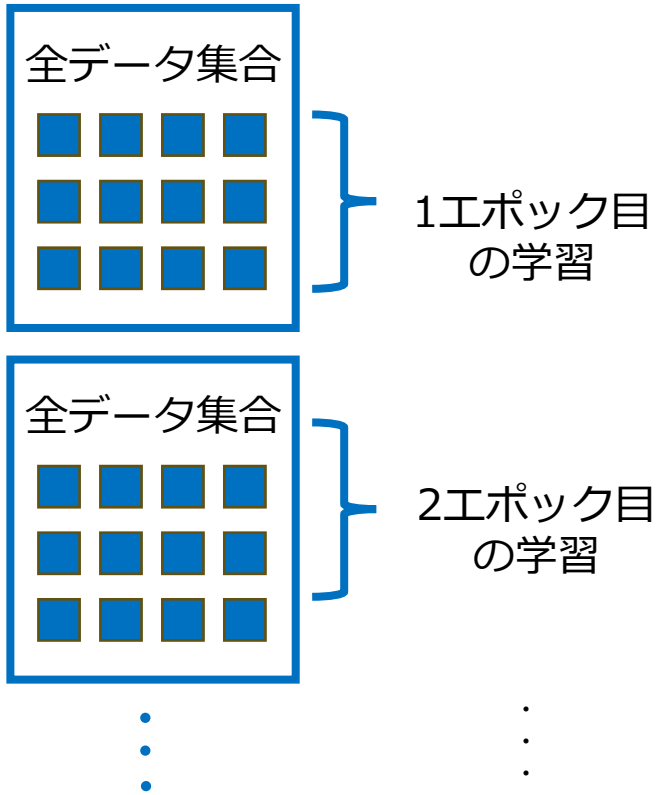
      ※ミニバッチ勾配降下法では，「バッチサイズ」という語は，バッチのサイズだけでなく，各ミニバッチに含まれるデータ数を意味する場合がある
    - **ミニバッチ（Mini-batch）**とは，バッチを分割した小さなデータ集合のこと



©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- ミニバッチ勾配降下法
  - パラメータ更新の度に「確率的」にミニバッチを選択して学習する方法
    - バッチサイズを1としたミニバッチ勾配降下法を**確率的勾配降下法（Stochastic Gradient Descent ; SGD）**という
    - 確率的にデータを選択することで，最適化が局所解に固定されにくくなる
    - データ集合を使って学習しても収束していない場合は，もう何周かしてみる
  - 全データ集合を1周回す単位を**エポック（Epoch）**という
    - 深層学習だと基本的に複数エポック必要
      （1エポックでは学習が収束しないことが多い）
    - エポックごとにデータをシャッフルし，
      分割して順番に使用する



©Yutaka Matsuo. All rights reserved.

ロジスティック回帰の学習

- ミニバッチ勾配降下法（バッチサイズ $M \ll N$ ）
  - クロスエントロピー誤差関数 E の勾配は簡単な式で表現することができる

$$E(\boldsymbol{y}, \hat{\boldsymbol{y}}) \equiv -\sum_{n=1}^{N}\sum_{k=1}^{K} y_{nk} \log \hat{y}_{nk}$$

$$\nabla_{w_k} E(w_k) = -\sum_{n=1}^{M} (y_{nk} - \hat{y}_{nk})\, x_n$$

$$\nabla_{b_k} E(b_k) = -\sum_{n=1}^{M} (y_{nk} - \hat{y}_{nk})$$

©Yutaka Matsuo. All rights reserved.

ロジスティック回帰と深層学習

- ロジスティック回帰モデルは深層学習と大いに関係がある
  - 詳細は次回の講義で説明する

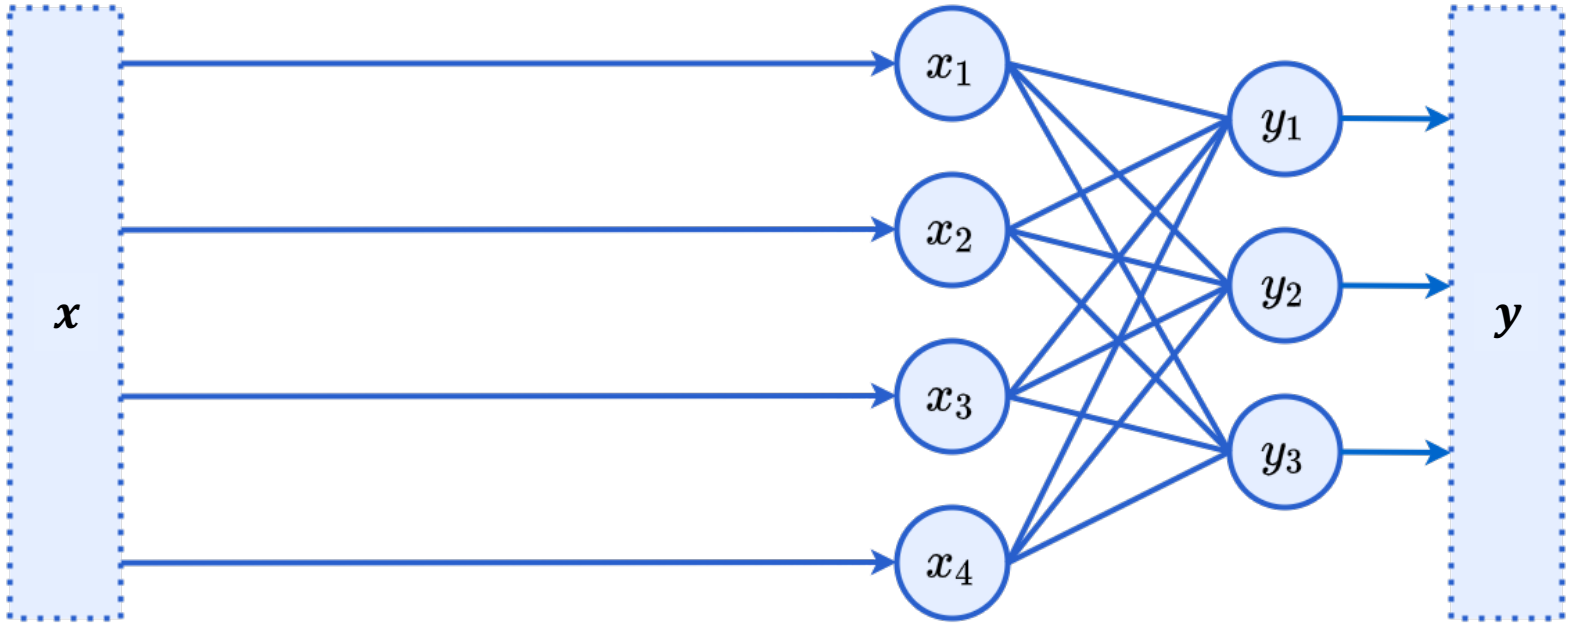
- ロジスティック回帰 ＝「浅い」ニューラルネットワーク
  - ニューラルネットワークでは入力を繰り返し変換することで
    有用な特徴を抽出し，その特徴量に基づいて予測を出力する

  - （分類問題を解く）ニューラルネットワークはその中間層を取り除くことで
    ロジスティック回帰モデルと等価になる

©Yutaka Matsuo. All rights reserved.

ロジスティック回帰と深層学習

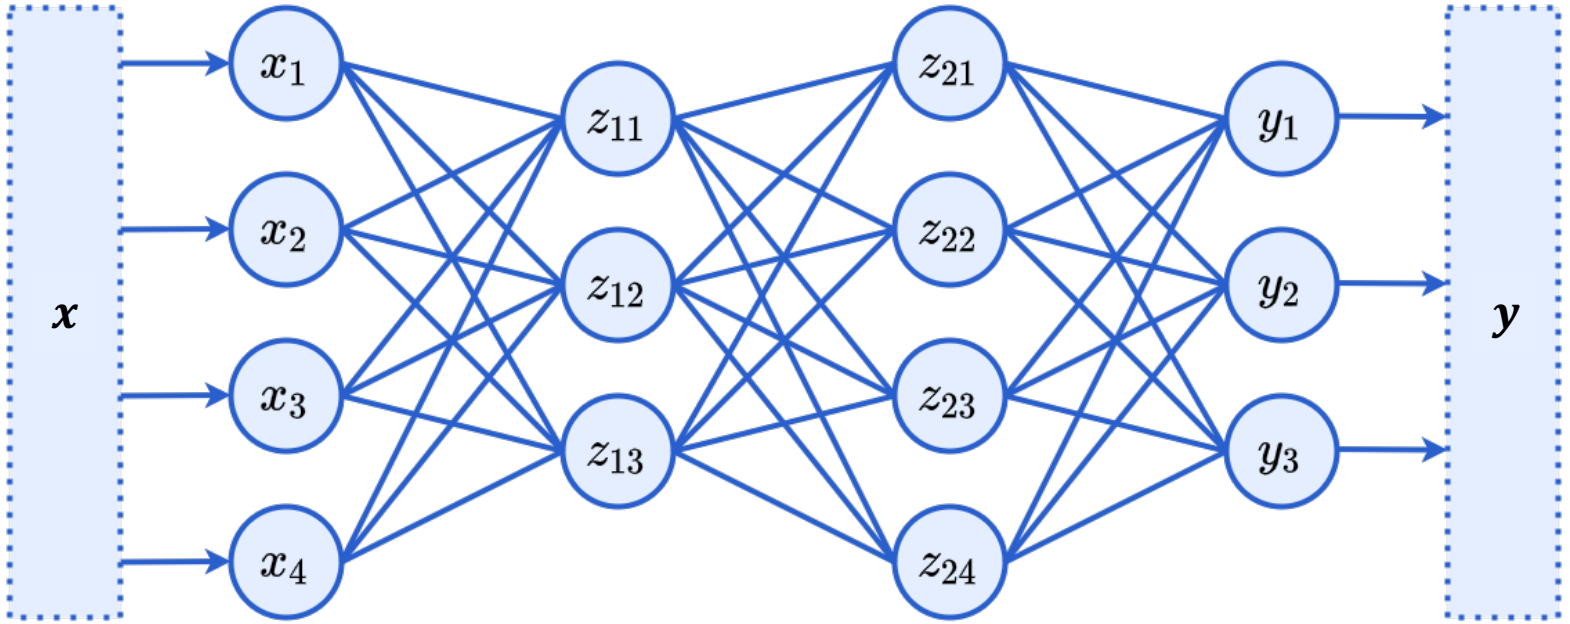
- ロジスティック回帰モデル



©Yutaka Matsuo. All rights reserved.

ロジスティック回帰と深層学習

- （フィードフォワード）ニューラルネットワーク



©Yutaka Matsuo. All rights reserved.

まとめ

- 機械学習
  - 機械学習は経験から学習するプログラムのことである
- 教師あり学習
  - 教師あり学習は機械学習の1分野で，入出力のペア $(\boldsymbol{x}, \boldsymbol{y})$ の集合を用いて学習を行う
  - 教師あり学習の問題には回帰・分類があり，
    分類問題を解く機械学習モデルとしてロジスティック回帰がある
- ロジスティック回帰
  - モデルの推論ではあるクラスに属する確率が出力される
  - モデルの学習では勾配降下法を実行する

©Yutaka Matsuo. All rights reserved.

今回の目的と目標

- **目的**
  - 深層学習を学ぶ事前知識として，機械学習の概要を把握する

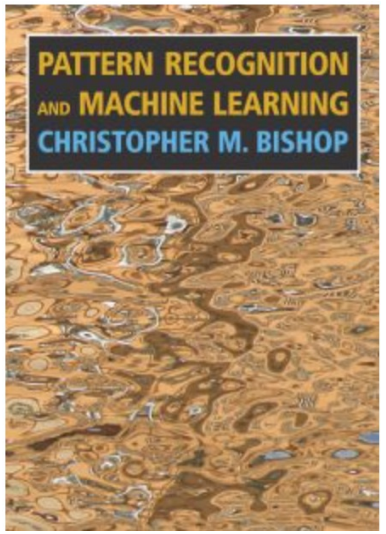
- **目標**
  - 機械学習とは何かを、枠組み（モデル，学習，推論）と共に説明できる
  - 機械学習にどういったアプリケーションがあるのかを説明できる
  - 分類問題と回帰問題の違いを説明できる
  - モデルの評価基準や観点を説明できる（汎化性能，過学習，性能指標…）
  - 数式を含めてロジスティック回帰を説明できる

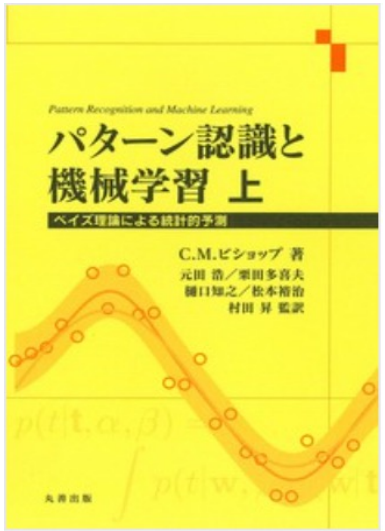
©Yutaka Matsuo. All rights reserved.

参考書籍

- Python機械学習プログラミング
  - https://book.impress.co.jp/books/1120101017
- パターン認識と機械学習 (Pattern Recognition and Machine Learning)
  - 英語版PDF（無料ダウンロード可能）
    https://www.microsoft.com/en-us/research/people/cmbishop/prml-book/
  - 日本語版書籍
    https://www.maruzen-publishing.co.jp/book/b10111651.html
    https://www.maruzen-publishing.co.jp/book/b10111678.html









©Yutaka Matsuo. All rights reserved.

補足：「推論」「推定」「学習」について

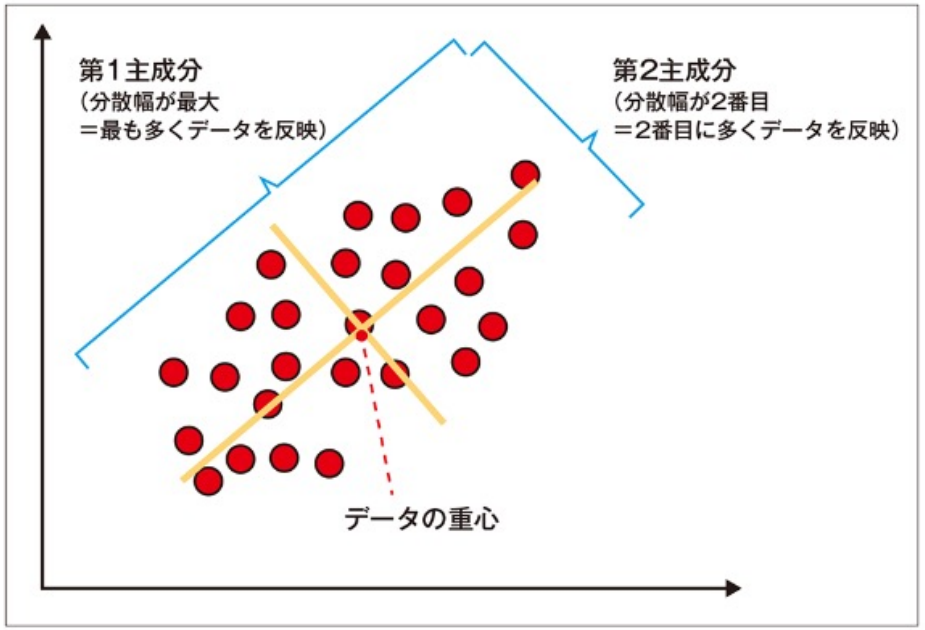
- 「推論」と「推定」について
  - 推論は未知の入力データに対する出力結果を求めること，推定はパラメータ値を求めること（=学習）と区別する
  - ベイズ推論の枠組みでは，これらは区別されない

- 「推定」と「学習」について
  - 推定は統計学，学習は機械学習で使われる言葉
  - 基本的にどちらも違いはない（推定の方は統計モデルを設計して，そのパラメータを求めることを念頭に置いている）
  - 本講義では，どちらも同じ意味だと思って構わない

©Yutaka Matsuo. All rights reserved.

補足：主成分分析

- **主成分分析（Principal Component Analysis ; PCA）**
  - 分析データに対して，分散幅が最大となる方向の成分を第一主成分という
  - 続いて，二番目に分散幅が大きい方向の成分を第二主成分という
  - 主成分分析によって，特定の特徴量を持つデータのみ抽出するので，データ数削減・データの次元削減になる

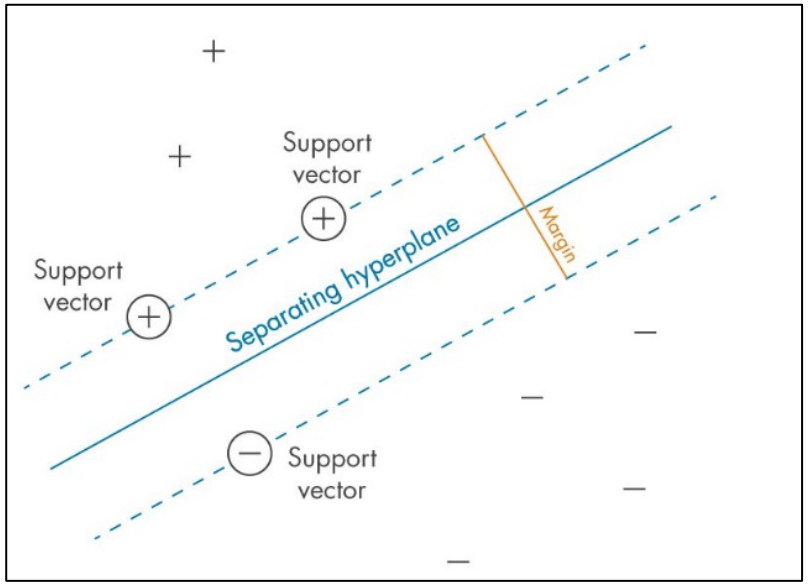


https://www.google.com/url?sa=i&url=https%3A%2F%2Fxtrend.nikkei.com%2Fatcl%2Fcontents%2F18%2F00076%2F00010%2F&psig=AOvVaw1NevSYobPFBDrDpQyUr44x&ust=1706646078996000&source=images&cd=vfe&opi=89978449&ved=0CBQQjhxqFwoTCODV-KC2g4QDFQAAAAAdAAAAABAM より図を引用

©Yutaka Matsuo. All rights reserved.

補足：サポートベクターマシン

- **サポートベクターマシン（Support Vector Machine ; SVM）**
  - 2クラス分類のための教師あり学習の手法
  - 分類境界と最も近いサンプルとの距離（マージン）を最大化するように学習する
    - 分類境界と最も近いサンプルをサポートベクターという
  - SVMはカーネル法と呼ばれるアルゴリズムの一種であり，データ集合を線形分離可能になるようにカーネル関数を用いて高次元空間にマッピングする
    - その際に計算コストが増加しないように上手く式変形する手法をカーネルトリックという

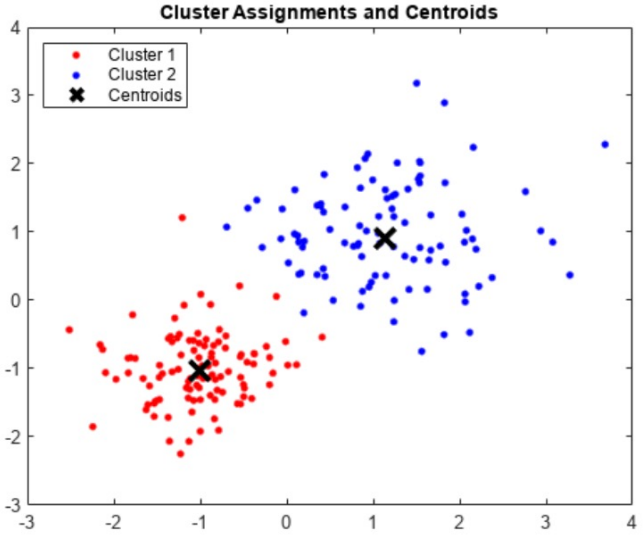


https://jp.mathworks.com/discovery/support-vector-machine.html より図を引用

©Yutaka Matsuo. All rights reserved.

補足：k-means法

- **k-means法**
  - クラスタリング（教師なし学習）のために使用される手法
  - データ集合をk個のクラスタに分けるアルゴリズム
    1. データ集合から，セントロイド（各クラスタの代表点）を k 個（$c_1, \ldots, c_k$）ランダムに選択
    2. 各データ x_i について，k 個のセントロイドのうち自分との距離が最も近いものを c_{x_i} とし，そのデータを c_{x_i} を含むクラスタに割り当てる
    3. 全データのクラスタへの割り当てが終了したら，各クラスタの重心を計算してそれらを新たなセントロイドとする
    4. 2.-3.を繰り返す
    5. クラスタの変化がなくなったら終了する
  - 課題
    - 初期値により計算量やクラスタリング結果が変わる
    - 改善手法として，k-means++法が提案されている



https://jp.mathworks.com/help/stats/kmeans.html

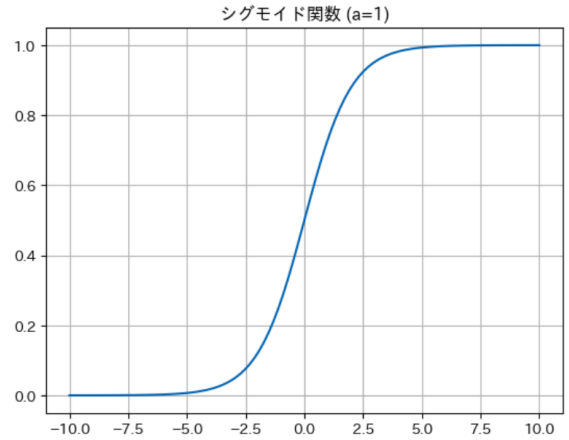
©Yutaka Matsuo. All rights reserved.

補足：シグモイド関数

• シグモイド関数（Sigmoid Function）

- 入力を(0,1)の範囲の確率値として出力することで，二値分類に多く用いられる
  ⇔ソフトマックス関数はマルチクラス分類で用いられる

  ※ 二値分類の場合にのみ，シグモイド関数の逆関数として
  $logit(p) = \ln(p/(1-p))$が定義できる
  マルチクラス分類の場合，ロジットをソフトマックス関数の
  逆関数として定義することはできない



- 実数値を $[0,1]$ の確率に変換する活性化関数
- 指数関数を適用して正規化を行う
- 出力値は「入力データがあるクラスに属する確率」であると考える

$$\sigma(x) = \frac{1}{1+\exp(-ax)} \quad (a > 0)$$

$$\sigma'(x) = a \cdot \exp(-ax)\left(\frac{1}{1+\exp(-ax)}\right)\left(\frac{1}{1+\exp(-ax)}\right)$$

$$= a \cdot \left(\frac{1+\exp(-ax)}{1+\exp(-ax)} - \frac{1}{1+\exp(-ax)}\right)\left(\frac{1}{1+\exp(-ax)}\right)$$

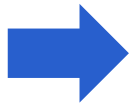
$$= a \cdot \big(1-\sigma(x)\big)\sigma(x)$$

©Yutaka Matsuo. All rights reserved.

補足：シグモイド関数 | 温度パラメータ

- シグモイド関数

$$\sigma(x) = \frac{1}{1 + \exp(-ax)} \ (a > 0)$$



$$\sigma(x) = \frac{1}{1 + \exp(-\frac{ax}{T})} \ (a > 0)$$

温度パラメータ$T(> 0)$を導入

- **温度パラメータ（Temperature Parameter）**
  - シグモイド関数の「急峻さ」を表すパラメータ
  - 二値分類やマルチクラス分類における分類の確信度を調整する
    - $T < 1$：$0 \rightarrow 1$への遷移がより急になる（分類の確信度を高める）
    - $T = 1$：通常のシグモイド関数
    - $T > 1$：$0 \rightarrow 1$への遷移が緩やかになる（分類の確信度を弱める）

©Yutaka Matsuo. All rights reserved.

補足：モデル候補集合

- モデル候補集合
  - 特定のタスク（たとえば画像分類や回帰分析など）を解くために考えられる複数のモデルの集まりのこと

1.異なるモデルタイプから候補を探す

- 線形回帰やロジスティック回帰
- 決定木やランダムフォレスト
- ニューラルネットワーク（深層学習モデル）　など

2.同じモデルタイプでハイパーパラメータを変える

- 学習率の調整
- バッチサイズの調整　など

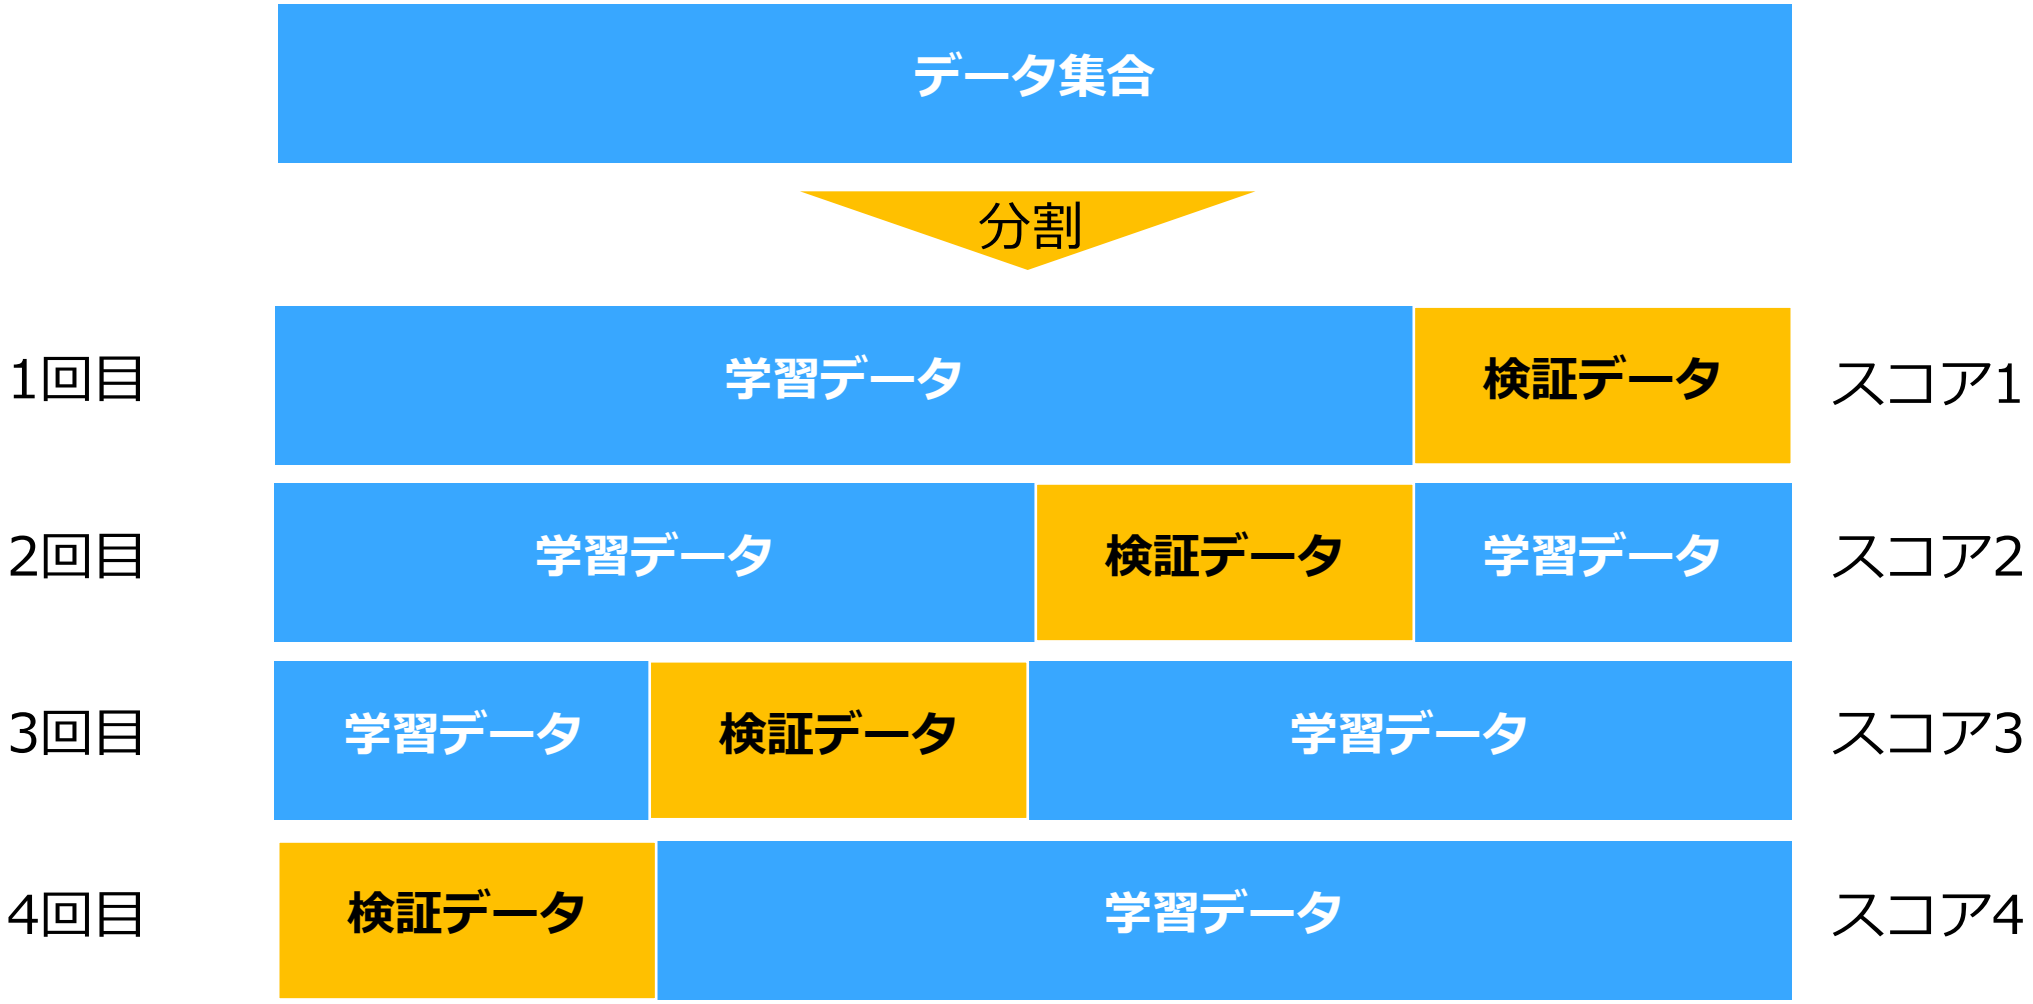
©Yutaka Matsuo. All rights reserved.

補足：交差検証

- **k分割交差検証（k-Fold Cross Validation）**
  - k 分割されたデータ集合のうち k -1 個を訓練データ，残り1個を検証データとして評価を行い， k 回の評価の平均をとる方法
  - 複数回評価を行うことでさらに一般的な性能を測ることができる
  - k 個のデータ集合が1回ずつ検証データとなるように k 回評価を行う
  - より多様なデータで検証を行うことができる（特にデータ集合が小さい場合には効果的である）

©Yutaka Matsuo. All rights reserved.

補足：4-分割検証法



平均スコア

©Yutaka Matsuo. All rights reserved.

補足：次元の呪いと特徴量選択

- **次元の呪い（The Curse of Dimensionality）**
  - データの次元数が大きくなると機械学習タスクの難易度が急激に高くなること
  - 変数が増えることでモデルが考慮すべき空間が指数関数的に増えてしまうことが原因
  - また高次元になるにつれ，データ点間の距離が意味を成さなくなってしまう

$$\lim_{d\to\infty} E\left(\frac{dist_{max}(d)-dist_{min}(d)}{dist_{min}(d)}\right) \to 0$$

https://en.wikipedia.org/wiki/Curse_of_dimensionality

- データの次元dが無限大（$d \to \infty$）に近づくとデータ点間の最大距離 $dist_{max}(d)$ と最小距離 $dist_{min}(d)$ の差が，最小距離に対して無視するほど小さくなる
- 例えば，低次元（例えば 2 次元や 3 次元）では，点同士の距離には大きなばらつきがあるが，高次元（100次元など）になると，ほぼすべての点が「ほぼ同じ距離」に分布するようになる

©Yutaka Matsuo. All rights reserved.

補足：次元の呪いと特徴量選択

- 次元の呪いを解決するために，**特徴量選択（Feature Selection）**や**次元圧縮（Dimensionality Compression）**のように次元を落とすことがある

- 特徴量選択：必要な変数を見極めて，不要な変数を削除する

- 次元圧縮：複数の次元を一つまたはより少数の次元にまとめる
  - 例：主成分分析（詳細は補足を参照）

©Yutaka Matsuo. All rights reserved.

©Yutaka Matsuo. All rights reserved.